

ALMA MATER STUDIORUM
UNIVERSITÀ DI BOLOGNA

Dipartimento di Informatica - Scienza e Ingegneria - DISI

**Corso di Laurea in Ingegneria Informatica -
Laurea Triennale**

Machine Learning per la stima della temperatura superficiale urbana da indici satellitari: applicazione a Bologna

Relatore:
Prof.
Andrea Borghesi

Presentata da:
Fabio Malagutti

Sessione Dicembre
Anno Accademico 2024/2025

«Non puoi insegnare qualcosa a un uomo. Puoi solo aiutarlo a scoprirla dentro di sé.»

Galileo Galilei

Abstract

L'aumento delle ondate di calore e dell'urbanizzazione rende sempre più importante comprendere e quantificare la temperatura superficiale urbana (LST) e i suoi driver. In questo lavoro si utilizzano i dati satellitari del progetto TALEA, relativi all'estate 2024 nel Comune di Bologna, per stimare la LST normalizzata (z-score) mediante tecniche di machine learning a partire da indici satellitari derivati.

Come variabili esplicative sono stati considerati l'NDVI medio (copertura vegetale), l'albedo medio (riflettanza superficiale) e due indici compositi (heat_veg_index, heat_retention_index). Sono stati confrontati tre modelli di regressione: Regressione Lineare, Random Forest Regressor e Gradient Boosting Regressor, valutati con split train/test (70/30) e successiva validazione incrociata 10-fold sul modello ritenuto più affidabile. È stato inoltre testato un arricchimento spaziale delle feature tramite NDVI medio calcolato in buffer di 100, 200 e 500 metri.

I risultati mostrano che i modelli ad alberi (in particolare la Random Forest con feature estese) sono in grado di ricostruire quasi perfettamente lo z-score della LST, mentre la Regressione Lineare non è in grado di catturare adeguatamente le relazioni non lineari tra variabili. L'analisi delle importanze conferma il ruolo centrale di NDVI e albedo, con un contributo aggiuntivo ma più contenuto degli indici compositi, mentre l'NDVI di vicinato risulta poco informativo nel dataset analizzato. Le prestazioni ottenute riflettono sia la forte relazione fisica tra vegetazione, riflettanza e temperatura superficiale urbana, sia la coerenza interna del dataset TALEA, suggerendo possibili applicazioni a supporto della valutazione e mitigazione dell'isola di calore urbana.

Indice

Lista delle figure 6

Acronimi **7**

Termini e definizioni **8**

1 Introduzione **9**

1.1 Contesto e motivazione 9

1.2 Obiettivi 10

1.3 Struttura 11

2 Contesto, dati TALEA e area di studio **13**

2.1 Il progetto TALEA 13

2.2 Area di studio: Bologna 14

2.3 Dataset utilizzati 15

2.4 Preparazione e pulizia dei dati 16

2.5 Analisi esplorativa 18

3 Metodologia di modellazione e validazione **21**

3.1 Breve introduzione al Machine Learning 21

3.2 Impostazione del problema di regressione 22

3.3 Modelli di machine learning utilizzati 23

3.4 Metriche di valutazione 25

3.5 Strategia di validazione 26

Codice e dati 27

4 Risultati dei modelli **29**

4.1 Modelli con feature base (NDVI + albedo) 30

4.2 Modelli con feature estese (NDVI + albedo + indici compositi) 35

4.3 Modello con NDVI di vicinato (100, 200, 500 m) 44
4.4 Validazione incrociata 10-fold della Random Forest estesa 45

5 Discussione e interpretazione nel contesto urbano 48
5.1 Perché i modelli ad alberi superano la regressione lineare 49
5.2 Ruolo fisico di NDVI, albedo e indici compositi 50
5.3 Irrelevanza delle feature NDVI a distanza nel caso specifico 51
5.4 Lettura spaziale dei risultati su Bologna 52
5.5 Limiti del lavoro 55

6 Conclusioni e sviluppi futuri 57
6.1 Sintesi dei risultati principali 57
6.2 Implicazioni operative 58
6.3 Sviluppi futuri 59

Bibliografia 60

Ringraziamenti 63

Elenco delle figure

2.1 Area di studio: territorio comunale di Bologna. 15

2.2 Distribuzione della LST normalizzata (`z_score`) sul dataset TALEA. 19

2.3 Relazione tra NDVI medio e albedo medio: plot a densità. La correlazione appare più visibile rappresentando la densità dei punti: le zone ad alta vegetazione mostrano sistematicamente valori di albedo più elevati. 20

4.1 Istogramma degli errori (z_score osservato meno z_score predetto) per la Regressione Lineare con feature base. 31

4.2 Istogramma degli errori (z_score osservato meno z_score predetto) per il modello Random Forest con feature base. 31

4.3 Istogramma degli errori (z_score osservato meno z_score predetto) per il modello Gradient Boosting con feature base. 32

4.4 Importanza relativa delle feature nel modello Random Forest con feature base (NDVI_mean, albedo_mean). 33

4.5 Confronto tra z_score osservato e z_score predetto dal modello Random Forest con feature base. La linea tratteggiata rappresenta la retta ideale $y = x$. 33

4.6 Distribuzione spaziale dello z_score osservato sul test set per il modello con feature base. 34

4.7 Mappa dei residui (z_score osservato meno z_score predetto) per il modello Random Forest con feature base. 35

4.8 Importanza relativa delle feature nel modello Random Forest con feature estese. 36

4.9 Matrice di correlazione tra NDVI_mean, albedo_mean, heat_veg_index e heat_retention_index.

4.10 Confronto tra z_score osservato e z_score predetto dal modello Random Forest con feature estese. La linea tratteggiata rappresenta la retta ideale $y = x$. 38

4.11 Istogramma degli errori (z_score osservato meno z_score predetto) per il modello Random Forest con feature estese. 38

4.12 Distribuzione spaziale dello z_score (osservato o predetto) per il modello Random Forest con feature estese. 39
4.13 Mappa dei residui (z_score osservato meno z_score predetto) per il modello Random Forest con feature estese. 40
4.14 Mappa dei residui in scala logaritmica $\log_{10}(|z_\text{true} - z_\text{pred}|)$ per il modello Random Forest con feature estese. 41
4.15 Poligoni del test set con errore assoluto maggiore (in rosso) per il modello Random Forest con feature estese; gli altri poligoni del test set sono mostrati in grigio. 43
4.16 Importanza relativa delle feature nel modello Random Forest con NDVI locale e NDVI di vicinato (100, 200, 500 m). 45
4.17 Istogramma degli errori out-of-fold (z_score osservato meno z_score predetto) per la Random Forest con feature estese in validazione incrociata 10-fold. 47

5.1 Confronto tra distribuzione spaziale dello `z_score` della LST (sinistra, valori più alti = aree relativamente più calde) e mappa dell'NDVI medio sul territorio comunale di Bologna. 53
5.2 Distribuzione spaziale dell'albedo media sul territorio comunale di Bologna. . . . 54

Acronimi

LST *Land Surface Temperature.* Temperatura superficiale terrestre stimata da satellite.

NDVI *Normalized Difference Vegetation Index.* Misura indiretta della vegetazione presente.

MAPE *Mean Absolute Percentage Error.* Errore percentuale medio.

RF *Random Forest.* Modello di apprendimento basato su ensemble di alberi.

GB *Gradient Boosting.* Modello non lineare addestrato sequenzialmente.

SUHI *Surface Urban Heat Island.* Isola di calore superficiale urbana.

Termini e definizioni

Albedo	Riflettanza superficiale: frazione della radiazione solare riflessa dalla superficie.
Z-score LST	LST normalizzata, utile per confrontare variazioni di temperatura su aree diverse.
Heat_veg_index	Indice composito del contributo mitigante della vegetazione.
Heat_retention_index	Indice della capacità dei materiali urbani di trattenere calore.
Random Forest	Modello di regressione classificato tra gli ensemble non lineari, stabile e robusto al rumore.
Gradient Boosting	Modello costruito tramite miglioramenti successivi di alberi decisionali, ottimo in presenza di relazioni non lineari.
Urban Heat Island	Fenomeno per cui le aree urbane risultano significativamente più calde rispetto alle zone rurali circostanti.

Capitolo 1

Introduzione

1.1 Contesto e motivazione

La temperatura superficiale terrestre (Land Surface Temperature, LST) è uno degli indicatori chiave per descrivere il clima urbano e, in particolare, il fenomeno dell'isola di calore urbana. Con questo termine si indica la tendenza delle aree urbanizzate a presentare temperature sistematicamente più elevate rispetto alle zone rurali circostanti, a causa della prevalenza di superfici impermeabili, della riduzione della vegetazione e delle proprietà radiative e termiche dei materiali edilizi. La LST rappresenta la "pelle" termica della città e consente di analizzare in modo spazialmente continuo dove il tessuto urbano tende ad accumulare e rilasciare più calore.

L'aumento delle temperature superficiali ha conseguenze dirette sul funzionamento delle città. Dal punto di vista del comfort termico, le condizioni microclimatiche possono diventare critiche in spazi pubblici, aree densamente edificate e quartieri con scarsa presenza di verde. A livello energetico, temperature urbane più elevate comportano un incremento della domanda di raffrescamento degli edifici, con effetti sui carichi di picco delle reti elettriche e sui consumi complessivi. Per la pianificazione urbana e le politiche di mitigazione, la distribuzione spaziale della LST costituisce un'informazione di base per individuare le aree più critiche e valutare l'efficacia potenziale di interventi come l'aumento della copertura vegetale o l'adozione di materiali ad alta riflettanza.

In questo contesto, le amministrazioni e i tecnici hanno bisogno di strumenti quantitativi basati su dati oggettivi e riproducibili. I dati satellitari permettono di misurare in modo coerente e su tutta l'area urbana sia la LST sia indici derivati dalla copertura del suolo, come l'NDVI (che descrive la presenza di vegetazione) e l'albedo (che rappresenta la capacità delle superfici di riflettere la radiazione solare). L'integrazione di questi indici con metodi di analisi

statistica e tecniche di machine learning consente non solo di mappare l'isola di calore urbana, ma anche di modellarne i principali driver e quantificare il contributo delle diverse componenti superficiali alla variabilità termica intraurbana.

Bologna rappresenta un caso di studio interessante per diverse ragioni. È una città di medie dimensioni con un centro storico denso e compatto, caratterizzato da edifici continui e superfici fortemente artificializzate, affiancato da quartieri residenziali, aree industriali e grandi infrastrutture. La presenza combinata di tessuti storici, comparti produttivi e aree verdi genera una marcata eterogeneità spaziale nelle condizioni termiche, che rende particolarmente adatto l'uso di dati satellitari ad alta risoluzione per analizzare la distribuzione della LST. Inoltre, la disponibilità di dataset già pre-elaborati nell'ambito del progetto TALEA fornisce una base dati coerente su cui sperimentare metodi di modellazione basati su machine learning e valutare, in modo quantitativo, il legame tra indici satellitari e temperatura superficiale urbana nel contesto bolognese.

1.2 Obiettivi

Gli obiettivi della tesi sono principalmente quattro.

Il primo obiettivo è stimare la temperatura superficiale urbana in forma normalizzata (z_score della LST) a partire da indici satellitari derivati, utilizzando i dataset vettoriali messi a disposizione dal progetto TALEA per il Comune di Bologna. In questo modo il problema viene impostato come una regressione supervisionata, in cui il modello deve ricostruire lo z_score della LST a partire da informazioni sulla copertura e sulle proprietà radiative del suolo urbano.

Il secondo obiettivo è analizzare in che misura le diverse variabili spiegano la variabilità termica intraurbana. In particolare, si vuole quantificare il contributo di NDVI (come proxy della presenza di vegetazione), dell'albedo (come indicatore della riflettanza superficiale) e di alcuni indici compositi (heat_veg_index e heat_retention_index) alla predizione della LST normalizzata, utilizzando strumenti come l'importanza delle feature nei modelli ad alberi e la correlazione tra le variabili.

Il terzo obiettivo è confrontare diversi modelli di machine learning per la regressione, valutandone prestazioni e robustezza. In tesi vengono considerati, in particolare, una Regressione Lineare, una Random Forest Regressor e un Gradient Boosting Regressor, confrontati tramite split train/test e validazione incrociata 10-fold sul modello ritenuto più promettente, al fine di identificare una configurazione affidabile per questo tipo di dati.

Infine, il quarto obiettivo è collegare i risultati numerici a un'interpretazione fisica e urbana del caso di studio. Le prestazioni dei modelli e le mappe di z_score predetto e dei residui vengono lette alla luce delle caratteristiche del tessuto urbano di Bologna (presenza di verde, materiali, configurazione dei quartieri), in modo da tradurre gli output del modello in indicazioni utili per comprendere la distribuzione spaziale della temperatura superficiale e i suoi principali driver.

1.3 Struttura

Il presente lavoro è strutturato come segue.

Il Capitolo 1 introduce il contesto e il problema urbano, descrivendo il fenomeno dell'isola di calore urbana e il ruolo della temperatura superficiale (LST) nelle città. Vengono presentati gli obiettivi della tesi e la motivazione dell'uso di dati satellitari e di tecniche di machine learning per il caso di studio di Bologna.

Il Capitolo 2 descrive il contesto dei dati utilizzati, con una panoramica sul progetto TA-LEA, sui prodotti satellitari disponibili (LST, NDVI, albedo e indici compositi) e sull'area di studio del Comune di Bologna. Sono inoltre illustrati i dataset impiegati, le principali variabili considerate, le operazioni di preparazione e pulizia dei dati e una breve analisi esplorativa della LST normalizzata.

Nel Capitolo 3 viene presentata la metodologia di modellazione. Si definisce il problema di regressione, si introducono le diverse configurazioni di feature (modello base, esteso e con feature spaziali) e si descrivono i modelli di machine learning adottati (Regressione Lineare, Random Forest Regressor, Gradient Boosting Regressor). Vengono infine discusse le metriche di valutazione e la strategia di validazione adottata, basata su split train/test e validazione incrociata 10-fold.

Il Capitolo 4 raccoglie i risultati sperimentali. Sono riportate e confrontate le prestazioni dei modelli sulle feature base e sulle feature estese, con analisi delle importanze delle variabili e delle correlazioni tra gli indici. Vengono inoltre presentati i risultati del modello con NDVI di vicinato e della validazione 10-fold sul modello Random Forest esteso, insieme a mappe di z_score predetto, residui e istogrammi degli errori.

Nel Capitolo 5 i risultati numerici vengono discussi e interpretati nel contesto urbano di Bologna. Si analizza perché i modelli ad alberi superano la regressione lineare, si approfondisce il ruolo fisico di NDVI, albedo e indici compositi nella spiegazione della variabilità termica intraurbana e si discute l'irrilevanza delle feature di NDVI a distanza nel caso specifico. Viene

inoltre proposta una lettura spaziale delle mappe ottenute e vengono evidenziati i principali limiti del lavoro.

Infine, il Capitolo 6 sintetizza le conclusioni principali della tesi, riassumendo i risultati più rilevanti e le implicazioni operative per l'analisi dell'isola di calore urbana. Vengono infine delineati alcuni possibili sviluppi futuri, tra cui l'integrazione di feature urbanistiche aggiuntive, la verifica della robustezza temporale dei modelli su altre stagioni o anni e l'estensione ad altri indici del progetto "TALEA".

Capitolo 2

Contesto, dati TALEA e area di studio

In questo capitolo vengono descritti il contesto applicativo e i dati utilizzati per lo sviluppo dei modelli di machine learning. Si introduce innanzitutto il progetto TALEA e i principali prodotti satellitari messi a disposizione per l'analisi della temperatura superficiale urbana. Successivamente viene presentata l'area di studio del Comune di Bologna, con le sue principali caratteristiche morfologiche e climatiche. Infine, si descrivono in dettaglio i dataset impiegati nella tesi, le operazioni di preparazione e pulizia dei dati e una breve analisi esplorativa della LST normalizzata.

2.1 Il progetto TALEA

TALEA è un progetto che ha come obiettivo principale la produzione e l'utilizzo di indicatori satellitari per descrivere il clima urbano e supportare la progettazione di interventi di mitigazione delle isole di calore. Nel caso di Bologna, il progetto mette a disposizione una serie di layer già pre-elaborati che descrivono in modo coerente la temperatura superficiale urbana e le principali caratteristiche della copertura del suolo, fornendo una base dati pronta per analisi quantitative e applicazioni di machine learning.

I prodotti generati includono, in forma sia raster sia vettoriale (GeoTIFF e GeoJSON), mappe di temperatura superficiale (LST) e dei principali indici derivati da immagini satellitari: NDVI (Normalized Difference Vegetation Index), che rappresenta la presenza e la "qualità" della vegetazione, e albedo, che descrive la capacità delle superfici di riflettere la radiazione solare. A questi si aggiungono una serie di indici compositi e derivati, come lo `heat_veg_index` (legato all'effetto mitigante del verde), lo `heat_retention_index` (relativo alla capacità delle superfici di trattenere il calore), l'*urban heat exposure index* (UHEI), lo `z_score` della LST e mappe di differenza giorno/notte (ad esempio `delta_lst` e relative classificazioni). I layer sono

già "clippati" sul confine comunale e organizzati in modo da poter essere letti direttamente con librerie come GeoPandas.

Il workflow che porta alla generazione di questi prodotti segue una sequenza tipica per l'elaborazione di dati satellitari: a partire da immagini multispettrali (ad esempio da Landsat 8/9 e MODIS) si eseguono le fasi di correzione e pre-processing, si calcolano gli indici spettrali (LST, NDVI, albedo) e, successivamente, si combinano tali indici per definire metriche derivate e indici compositi specifici per l'analisi del clima urbano. Il risultato è un set di mappe tematiche coerenti tra loro, che possono essere utilizzate sia per analisi descrittive sia, come in questa tesi, come input per modelli di regressione volti a spiegare e prevedere la variabilità della temperatura superficiale urbana.

2.2 Area di studio: Bologna

L'area di studio considerata in questa tesi è il territorio comunale di Bologna. La città è situata nel settore centro-settentrionale dell'Italia, nella porzione orientale della Pianura Padana, ai piedi dell'Appennino. Questa posizione geografica comporta un clima di tipo temperato continentale, caratterizzato da estati calde e spesso umide, con episodi ricorrenti di ondate di calore e condizioni favorevoli all'accumulo di calore nelle aree urbanizzate. Dal punto di vista dell'analisi della temperatura superficiale, il contesto della pianura padana, con scarsa ventilazione e forte antropizzazione, rende Bologna un caso studio rappresentativo per lo studio delle isole di calore urbane.

Il tessuto urbano di Bologna presenta caratteristiche eterogenee che influenzano in modo diretto la LST. Il centro storico è denso e compatto, con edifici continui, superfici prevalentemente impermeabili e un'elevata presenza di materiali edilizi in grado di accumulare calore. Attorno al centro si sviluppano quartieri residenziali con tessuti misti, in cui la presenza di aree verdi e spazi aperti varia sensibilmente da zona a zona. Sono inoltre presenti comparti industriali e commerciali, caratterizzati da grandi superfici coperte, parcheggi e infrastrutture, che tendono a generare valori di LST elevati. La distribuzione di parchi urbani, viali alberati e aree agricole residue introduce discontinuità locali nella copertura vegetale, con un impatto diretto sugli indici di NDVI e, di conseguenza, sulla temperatura superficiale.

I dataset TALEA utilizzati in questa tesi si riferiscono all'estate 2024 e forniscono, per il territorio del Comune di Bologna, mappe già clippate al confine amministrativo. In questo modo l'analisi è focalizzata sulla scala urbana, mantenendo una coerenza temporale tra le diverse variabili considerate (LST, NDVI, albedo e indici compositi). Una mappa di base del

territorio comunale, utilizzata come riferimento cartografico per l'interpretazione dei risultati, è riportata in Figura 2.1.

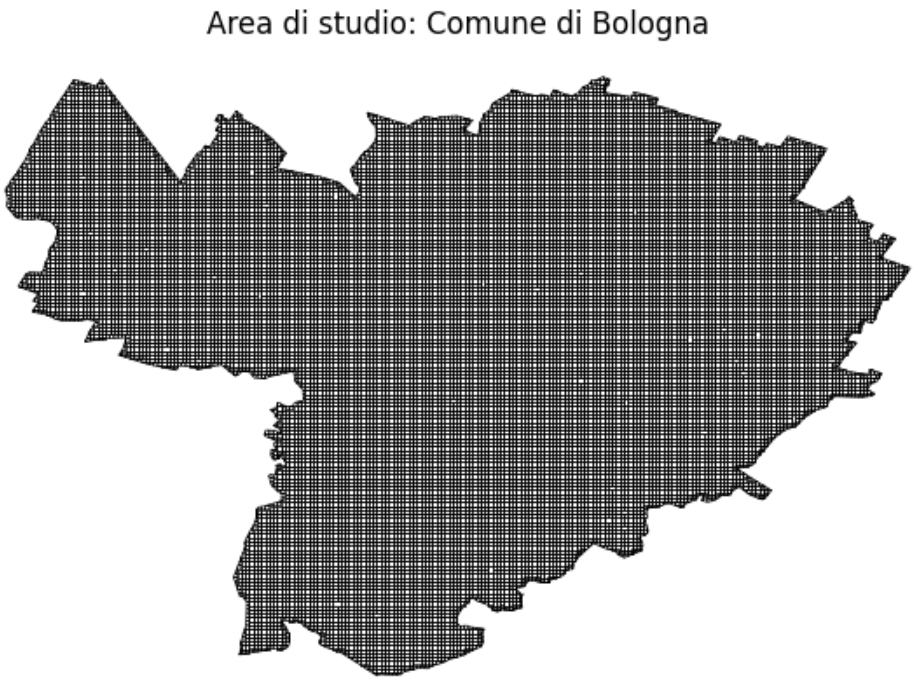


Figura 2.1: Area di studio: territorio comunale di Bologna.

2.3 Dataset utilizzati

In questa tesi il problema di regressione viene formulato utilizzando come variabile dipendente lo `z_score` della temperatura superficiale (LST), fornito dal progetto TALEA. Lo `z_score` è una versione normalizzata della LST, ottenuta sottraendo la media e dividendo per la deviazione standard su un insieme di riferimento. In altre parole, esprime di quante deviazioni standard un certo valore di LST si discosta dalla media. Rispetto alla LST grezza (ad esempio espressa in Kelvin o gradi Celsius), la versione normalizzata consente di lavorare con una scala adimensionale, rendendo più immediato il confronto tra aree relativamente più calde o più fredde all'interno della città e facilitando l'utilizzo di metriche standardizzate nelle fasi di modellazione.

Le variabili esplicative principali considerate in questo lavoro sono indici satellitari derivati dalla copertura del suolo. In particolare:

- `ndvi_mean`, che rappresenta il valore medio dell'NDVI (Normalized Difference Vegetation Index) sulla geometria elementare e costituisce una proxy della presenza e "intensità" della vegetazione, ovvero della componente biotica del suolo urbano;

- `albedo_mean`, che misura la riflettanza media delle superfici e descrive la componente radiativa, cioè quanto una certa area tende a riflettere o assorbire la radiazione solare incidente;
- `heat_veg_index`, un indice composito legato all'effetto mitigante del verde rispetto alle condizioni termiche locali;
- `heat_retention_index`, che sintetizza la capacità delle superfici urbane di accumulare e trattenere calore nel tempo.

Queste variabili, prese congiuntamente, permettono di descrivere in modo compatto sia la quantità di vegetazione sia le proprietà radiative e termiche dei materiali, che sono i principali driver della temperatura superficiale urbana.

Dal punto di vista del formato, i dati TALEA utilizzati in tesi sono forniti anche in forma vettoriale (GeoJSON), in cui ogni record associa la geometria di un poligono/pixel alle corrispondenti variabili numeriche (LST, NDVI, albedo, indici compositi). Questa rappresentazione è particolarmente adatta all'uso con librerie come GeoPandas e con modelli di machine learning tabellare: ogni poligono diventa una riga di un DataFrame, con uno schema chiaro "un'osservazione = un poligono", senza la necessità di gestire direttamente la struttura raster nelle fasi di addestramento.

È importante sottolineare che, per come è costruito il dataset TALEA, può esistere una dipendenza strutturale tra la LST (e il suo `z_score`) e alcuni indici derivati, in particolare NDVI e albedo. Ciò significa che parte della relazione tra target e feature potrebbe essere incorporata già nel processo di generazione degli indici, introducendo una forma di *data leakage* a livello di dataset. Questo aspetto non invalida l'analisi, ma va tenuto in considerazione nell'interpretazione delle prestazioni dei modelli e viene ripreso esplicitamente nella discussione sui limiti del lavoro.

2.4 Preparazione e pulizia dei dati

Prima di procedere alla modellazione è stato necessario eseguire una fase di preparazione e pulizia dei dati, in modo da ottenere un unico dataset coerente e direttamente utilizzabile dai modelli di regressione.

I layer forniti dal progetto TALEA sono disponibili in formato GeoJSON. Alcuni file presentano, tuttavia, piccoli problemi di formattazione (ad esempio troncamenti in fondo al file) che possono causare errori in fase di parsing standard. Per gestire questa situazione è stata

implementata una funzione di lettura "tollerante", che carica il contenuto del file come testo, intercetta eventuali errori di decodifica JSON e, in tal caso, tronca il file all'ultima parentesi di chiusura valida prima di effettuare nuovamente il parsing. In questo modo è stato possibile utilizzare in modo robusto anche file non perfettamente formati.

Un secondo passaggio riguarda la pulizia delle colonne numeriche. Alcuni attributi nei GeoJSON (ad esempio quelli etichettati come `value`) contengono valori codificati come stringhe, talvolta con più numeri concatenati o con formati non immediatamente convertibili a `float`. Per risolvere questo problema è stata definita una funzione che, dato un valore testuale, estrae tramite espressioni regolari il primo numero in formato decimale presente nella stringa e lo converte in `float`, restituendo valori mancanti (`NaN`) in assenza di numeri validi. Le colonne di interesse (NDVI, albedo, z_score e indici compositi) sono state quindi trasformate in colonne numeriche pulite.

Una volta letti e ripuliti i singoli layer (NDVI, albedo, z_score, `heat_veg_index`, `heat_retention_index`), è stato creato per ciascuno un identificatore univoco `gid`, assegnato come indice progressivo alle geometrie. Questo identificatore è stato utilizzato per eseguire il merge dei diversi layer in un unico `GeoDataFrame`, in cui ogni riga rappresenta un poligono/pixel e contiene tutte le variabili necessarie alla modellazione (feature e target), insieme alla geometria associata. In questo modo si è ottenuta una struttura tabellare coerente, pronta per essere collegata agli algoritmi di machine learning.

Per quanto riguarda i sistemi di riferimento, i layer TALEA sono forniti in genere in WGS84 (EPSG:4326), che è stato mantenuto come CRS principale per le analisi puramente tabellari e per la rappresentazione cartografica. Nei casi in cui è stato necessario calcolare buffer metrici (ad esempio per le feature di NDVI di vicinato), il `GeoDataFrame` è stato temporaneamente proiettato in un sistema di coordinate metriche adatto all'area di Bologna (ad esempio UTM zona 32N, EPSG:32632), in modo che le distanze fossero espresse in metri e i buffer avessero un significato geometrico corretto.

Infine, il dataset combinato è stato sottoposto a un controllo di completezza: sono state eliminate le righe con valori mancanti nelle variabili chiave per la modellazione (in particolare `ndvi_mean`, `albedo_mean` e `z_score`, oltre agli indici compositi quando utilizzati). Questo passaggio garantisce che i modelli vengano addestrati e valutati su un insieme di osservazioni consistente, senza dover gestire valori mancanti in fase di training o predizione.

Ambiente di lavoro e librerie utilizzate

Tutta l'analisi è stata svolta in Python 3 utilizzando principalmente le librerie `pandas` per la gestione dei dati tabellari, `geopandas` per i dati geospaziali vettoriali, `scikit-learn` per l'implementazione dei modelli di regressione e `matplotlib` per la produzione delle figure. Queste librerie permettono di costruire un workflow riproducibile che va dalla lettura dei file GeoJSON TALEA, alla preparazione del dataset combinato, fino all'addestramento, validazione e visualizzazione dei risultati dei modelli.

2.5 Analisi esplorativa

Inizialmente è stata svolta una breve analisi esplorativa sui dati combinati, con l'obiettivo di descrivere in modo sintetico la distribuzione della temperatura superficiale normalizzata e di verificare alcune relazioni di base tra gli indici satellitari principali.

Per quanto riguarda il target, lo `z_score` della LST, le statistiche descrittive mostrano una distribuzione centrata intorno a valori leggermente negativi (media circa -0.16) con una deviazione standard di circa 1.19. I quantili indicano che il 50% delle osservazioni si trova in un intervallo relativamente stretto attorno alla media (mediana vicina a zero), mentre le code raggiungono valori intorno a -3 e a oltre $+5$ deviazioni standard. L'istogramma riportato in Figura 2.2 evidenzia questa struttura: una massa principale di valori concentrata attorno allo zero, con un numero più ridotto di poligoni che presentano anomalie termiche marcate (positive o negative).

Un secondo passo ha riguardato la relazione tra `ndvi_mean` e `albedo_mean`, le due feature di base utilizzate nei modelli. Il coefficiente di correlazione lineare tra NDVI medio e albedo medio risulta elevato e positivo (circa $r \approx 0.91$), indicando che, nel dataset considerato, le aree più verdi tendono anche a presentare valori di albedo maggiori. Per visualizzare meglio questa relazione, è stato utilizzato un grafico a densità (Figura 2.3), in cui la concentrazione dei punti nel piano NDVI–albedo è rappresentata tramite una mappa di colori.

Dal punto di vista fisico, questa relazione è coerente con l'interpretazione dei due indici: NDVI descrive la presenza di vegetazione (che in genere è meno assorbente di molte superfici artificiali scure) e l'albedo misura la frazione di radiazione riflessa. Avere NDVI e albedo entrambi elevati significa, nella pratica, trovarsi in aree dove il suolo è coperto in buona parte da vegetazione o materiali relativamente chiari, condizioni che tendono a limitare l'accumulo di calore superficiale. La coerenza tra statistiche descrittive, istogramma dello `z_score` e correla-

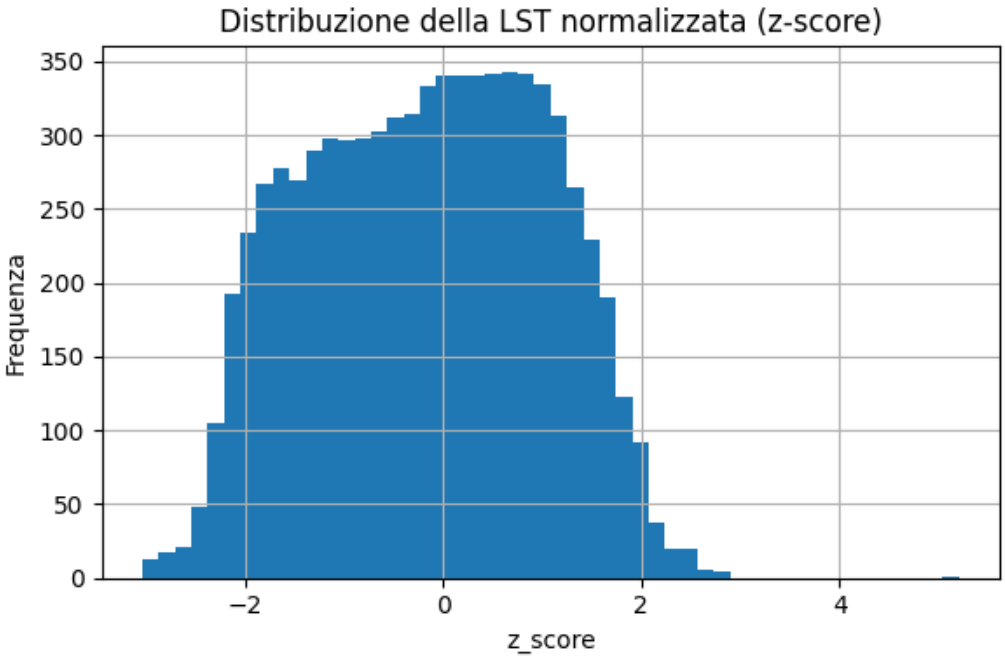


Figura 2.2: Distribuzione della LST normalizzata (`z_score`) sul dataset TALEA.

zione NDVI–albedo fornisce una prima conferma qualitativa del fatto che gli indici scelti sono ragionevolmente collegati ai meccanismi fisici alla base della temperatura superficiale urbana.

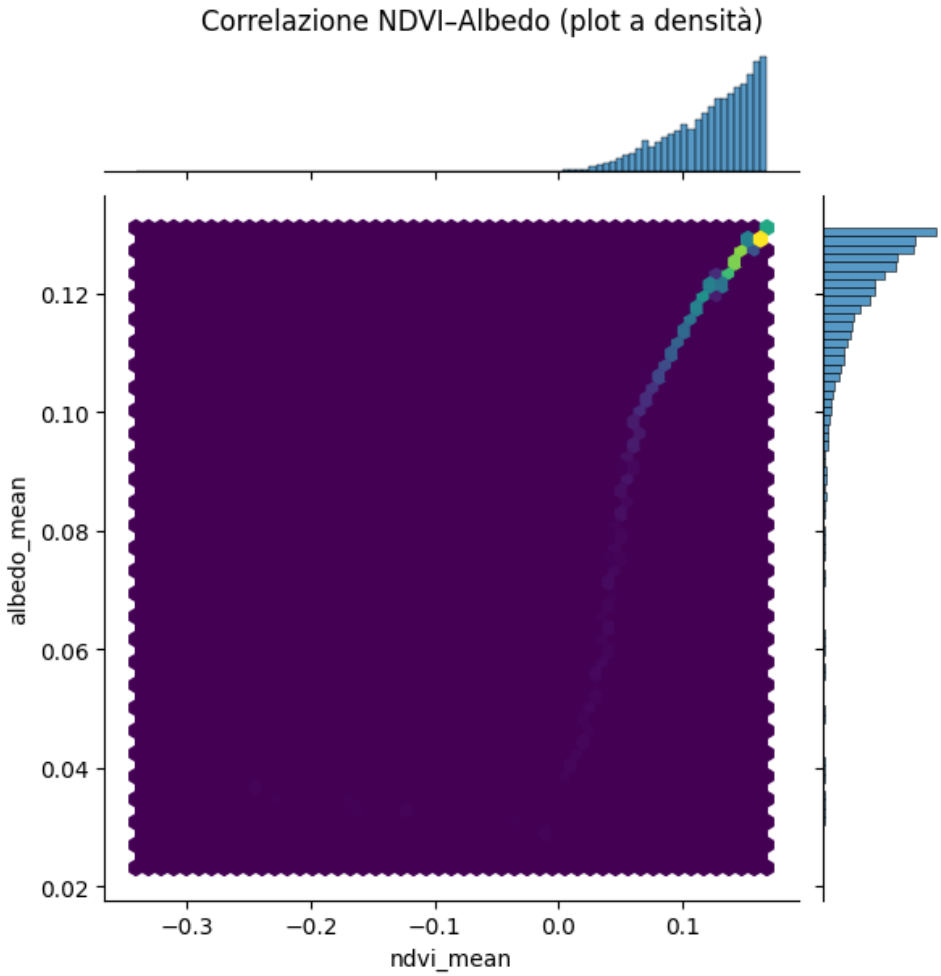


Figura 2.3: Relazione tra NDVI medio e albedo medio: plot a densità. La correlazione appare più visibile rappresentando la densità dei punti: le zone ad alta vegetazione mostrano sistematicamente valori di albedo più elevati.

Capitolo 3

Metodologia di modellazione e validazione

In questo capitolo viene descritta la metodologia adottata per costruire, addestrare e valutare i modelli di regressione utilizzati per stimare lo `z_score` della temperatura superficiale urbana a partire dagli indici satellitari del progetto TALEA. A partire dal dataset descritto nel Capitolo 2, il problema viene formalizzato come regressione supervisionata a livello di poligono e vengono definite diverse configurazioni di feature, che permettono di confrontare un modello di base con versioni via via più ricche di informazioni.

Dopo aver fissato l'impostazione del problema e le combinazioni di variabili esplicative considerate, vengono introdotti i tre modelli di machine learning impiegati in tesi: una Regressione Lineare come riferimento semplice e interpretabile, una Random Forest Regressor e un Gradient Boosting Regressor come esempi di modelli ad alberi in grado di catturare relazioni non lineari e interazioni tra feature. Per ciascuno di essi vengono richiamate brevemente le idee principali e le caratteristiche più rilevanti ai fini dell'applicazione.

Successivamente vengono presentate le metriche utilizzate per valutare le prestazioni dei modelli, con particolare attenzione a RMSE, MAE e R^2, e viene discussa in modo esplicito la MAPE, evidenziandone i limiti nel caso di target spesso vicino a zero come lo `z_score`. Infine, viene descritta la strategia di validazione adottata, basata su uno split train/test 70/30 per il confronto iniziale tra modelli e su una validazione incrociata 10-fold applicata al modello ritenuto più affidabile, al fine di ottenere una stima più robusta della capacità di generalizzazione.

3.1 Breve introduzione al Machine Learning

In questa tesi si utilizzano tecniche di *Machine Learning* (ML) per modellare la relazione tra indici satellitari e temperatura superficiale urbana. In termini generali, il ML studia modelli

in grado di apprendere schemi dai dati e di migliorare le proprie prestazioni su un compito specifico man mano che l'insieme di esempi disponibili aumenta.

Il problema affrontato è un classico caso di *apprendimento supervisionato*: a ogni poligono del territorio comunale è associato un vettore di feature (indici satellitari) e un valore reale di riferimento (target), lo `z_score` della LST. L'obiettivo del modello è stimare una funzione che, dato il vettore di feature in ingresso, restituisca una predizione del target il più possibile vicina al valore osservato.

Dal punto di vista del tipo di uscita, il problema rientra nella categoria della *regressione*: il target è una variabile continua e le prestazioni dei modelli vengono valutate tramite metriche come RMSE, MAE e coefficiente di determinazione R^2.

3.2 Impostazione del problema di regressione

In questa tesi il problema viene impostato come una regressione supervisionata a livello di poligono. Ogni osservazione corrisponde a una geometria elementare del dataset TALEA (pixel/poligono sul territorio comunale di Bologna) e il modello ha il compito di predire il valore di `z_score` associato a quella geometria, a partire da un insieme di indici satellitari utilizzati come variabili esplicative. Formalmente, dato un vettore di feature $\mathbf{x}_i$ per il poligono i (che contiene indici come NDVI medio, albedo medio e indici compositi), l'obiettivo è costruire una funzione $f(\mathbf{x})$ tale che:

$$\hat{z}_i = f(\mathbf{x}_i) \approx z_i,$$

dove z_i è lo `z_score` osservato della LST e $\hat{z}_i$ è la predizione del modello.

Per analizzare il ruolo delle diverse variabili a disposizione, sono state considerate tre configurazioni di feature principali:

- **Modello base**: usa come feature soltanto `ndvi_mean` e `albedo_mean`. Questa configurazione rappresenta il caso più semplice e direttamente interpretabile, in cui la temperatura superficiale normalizzata viene spiegata esclusivamente a partire dalla copertura vegetale media e dalla riflettanza media delle superfici. Serve come riferimento per valutare quanto NDVI e albedo, da soli, siano in grado di ricostruire la variabilità termica intraurbana.

- **Modello esteso**: aggiunge alle due feature di base gli indici compositi `heat_veg_index` e `heat_retention_index`. In questo modo il vettore delle feature diventa

$$\mathbf{x}_i = \big(\texttt{ndvi_mean}, \texttt{albedo_mean}, \texttt{heat_veg_index}, \texttt{heat_retention_index}\big)_i.$$

Questa configurazione permette di verificare se indici che combinano informazioni sulla vegetazione e sulla capacità delle superfici di trattenere calore portano un guadagno in termini di accuratezza rispetto al modello base e di quantificare il loro contributo alla predizione della LST normalizzata.

- **Modello con NDVI di vicinato**: estende il modello base aggiungendo le medie di NDVI calcolate entro buffer di raggio 100, 200 e 500 m (`ndvi_mean_100m`, `ndvi_mean_200m`, `ndvi_mean_500m`). Questa configurazione permette di verificare se l'informazione sul verde circostante alla cella aggiunge valore rispetto al solo NDVI locale.

3.3 Modelli di machine learning utilizzati

In questa sezione vengono descritti i tre modelli di regressione utilizzati in tesi: Regressione Lineare, Random Forest Regressor e Gradient Boosting Regressor. Tutti i modelli sono stati implementati tramite la libreria `scikit-learn`, utilizzando configurazioni coerenti con gli obiettivi di confronto tra approcci lineari e ad alberi.

Regressione lineare

La Regressione Lineare rappresenta il modello più semplice e immediatamente interpretabile considerato in questo lavoro. L'ipotesi di base è che il target (in questo caso lo `z_score` della LST) possa essere espresso come combinazione lineare delle feature, più un termine di errore:

$$z_i = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_p x_{ip} + \varepsilon_i,$$

dove x_{ij} sono le variabili esplicative e β_j i coefficienti da stimare. Il modello è addestrato minimizzando la somma dei quadrati degli errori (metodo dei minimi quadrati), e i coefficienti ottenuti sono direttamente interpretabili come contributo marginale di ciascuna feature sul target, a parità delle altre.

L'utilizzo della Regressione Lineare richiede alcune assunzioni implicite: la relazione tra feature e target è approssimativamente lineare, l'effetto delle variabili è additivo e non vi sono interazioni non modellate tra le feature. Inoltre, la presenza di collinearità forte tra le variabili può rendere instabili i coefficienti stimati e ridurre la capacità interpretativa del modello. Nel contesto di questa tesi, la Regressione Lineare viene usata principalmente come baseline: un riferimento semplice con cui confrontare le prestazioni e la flessibilità dei modelli ad alberi, che non richiedono una forma funzionale prefissata.

Random Forest Regressor

La Random Forest Regressor è un modello ensemble basato su alberi decisionali, costruito secondo il principio del *bagging* (bootstrap aggregating). L'idea di base è addestrare molti alberi di decisione indipendenti, ciascuno su un sottoinsieme campionato con rimpiazzamento del dataset originale e, a ogni split dell'albero, su un sottoinsieme casuale delle feature. La predizione finale è ottenuta come media delle predizioni dei singoli alberi.

Questa strategia introduce diversità tra gli alberi e riduce la varianza del modello rispetto a un singolo albero, migliorando la robustezza rispetto al rumore e al rischio di overfitting. Inoltre, gli alberi di decisione sono in grado di catturare relazioni non lineari e interazioni tra variabili senza che tali relazioni debbano essere specificate a priori. Un ulteriore vantaggio della Random Forest è la possibilità di stimare l'importanza relativa delle feature, ad esempio misurando la riduzione media dell'impurità (o dell'errore) attribuibile a ciascuna variabile nelle diverse partizioni. In questo lavoro, la Random Forest viene utilizzata sia come modello predittivo principale sia come strumento per quantificare il ruolo di NDVI, albedo e indici compositi nella spiegazione della LST normalizzata.

Gradient Boosting Regressor

Il Gradient Boosting Regressor è un altro modello ensemble basato su alberi decisionali, ma si fonda sul principio del *boosting* anziché del bagging. In questo caso gli alberi non sono addestrati in parallelo e in modo indipendente, ma in sequenza: ogni nuovo albero viene addestrato per correggere gli errori commessi dal modello corrente, approssimando il gradiente negativo della funzione di perdita rispetto alle predizioni. Il modello finale è una somma pesata di molti alberi "deboli" (a bassa profondità), ciascuno specializzato nel ridurre l'errore residuo dei precedenti.

Rispetto alla Random Forest, il Gradient Boosting tende a produrre modelli spesso più accurati, al prezzo di una maggiore sensibilità alla scelta degli iperparametri (numero di alberi, learning rate, profondità massima) e a un rischio di overfitting più marcato se non regolarizzato correttamente. Anche il Gradient Boosting è in grado di modellare relazioni non lineari e interazioni tra feature, ma lo fa tramite una costruzione incrementale che privilegia le direzioni dello spazio delle feature che spiegano meglio gli errori residui.

Nel contesto di questa tesi, il Gradient Boosting viene utilizzato come secondo modello ad alberi per confrontare un approccio basato su bagging (Random Forest) con uno basato su boosting, valutando se la correzione iterativa degli errori porta benefici significativi in termini di accuratezza nella predizione dello `z_score` della LST rispetto alla Random Forest.

Nel complesso, in questa tesi si è scelto di utilizzare configurazioni relativamente semplici per i modelli ad alberi. Salvo diversa indicazione, per Random Forest e Gradient Boosting sono stati mantenuti gli iperparametri di default di `scikit-learn`, verificando a posteriori che un aumento del numero di alberi non portasse miglioramenti significativi alle metriche di valutazione.

3.4 Metriche di valutazione

Per confrontare le prestazioni dei diversi modelli di regressione sono state utilizzate quattro metriche standard: RMSE, MAE, R^2 e MAPE. In questa sezione se ne richiamano brevemente definizione e significato intuitivo, con una discussione specifica sul comportamento della MAPE nel caso del target normalizzato `z_score`.

RMSE: Root Mean Squared Error

L'RMSE (Root Mean Squared Error) è definito come:

$$\text{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(z_i - \hat{z}_i)^2},$$

dove z_i è il valore osservato dello `z_score` per l'osservazione i, $\hat{z}_i$ è la corrispondente predizione del modello e n è il numero totale di osservazioni. L'RMSE misura la radice della media dei quadrati degli errori e penalizza in modo più forte gli errori grandi rispetto a quelli piccoli. In termini intuitivi, indica di quanto, in media, le predizioni si discostano dal valore reale, con unità di misura uguale a quella del target (in questo caso adimensionale).

MAE: Mean Absolute Error

Il MAE (Mean Absolute Error) è definito come:

$$\text{MAE} = \frac{1}{n}\sum_{i=1}^{n}|z_i - \hat{z}_i|.$$

Misura l'errore assoluto medio tra valori osservati e predetti. A differenza dell'RMSE, non eleva al quadrato gli errori e quindi penalizza in modo lineare gli scostamenti, risultando meno sensibile agli outlier. Fornisce una stima diretta dello scarto medio tra predizione e dato reale, espressa nelle stesse unità del target.

R^2: coefficiente di determinazione

Il coefficiente di determinazione R^2 è definito come:

$$R^2 = 1 - \frac{\sum_{i=1}^{n}(z_i - \hat{z}_i)^2}{\sum_{i=1}^{n}(z_i - \bar{z})^2},$$

dove $\bar{z}$ è la media dei valori osservati. Esprime la frazione di varianza del target spiegata dal modello rispetto a un modello banale che predice sempre la media. Un valore di R^2 vicino a 1 indica che il modello spiega quasi tutta la variabilità dei dati, mentre valori prossimi a 0 indicano che il modello non migliora in modo significativo rispetto alla media costante. Nel contesto di questa tesi, R^2 è utile per valutare quanto NDVI, albedo e indici compositi riescano a spiegare la variabilità dello `z_score` della LST.

MAPE: Mean Absolute Percentage Error

La MAPE (Mean Absolute Percentage Error) è definita come:

$$\text{MAPE} = \frac{100}{n}\sum_{i=1}^{n}\left|\frac{z_i - \hat{z}_i}{z_i}\right|.$$

Misura l'errore medio in termini percentuali rispetto al valore osservato e viene spesso usata quando il target è strettamente positivo e ha un'interpretazione naturale in percentuale (ad esempio volumi di vendita, consumi, ecc.).

Nel caso di questa tesi, il target è lo `z_score` della LST, che per definizione può assumere valori positivi, negativi e spesso prossimi a zero. Questo rende la MAPE una metrica problematica: quando z_i è molto vicino a zero, il denominatore nella frazione $\frac{z_i - \hat{z}_i}{z_i}$ diventa molto piccolo, e anche errori numericamente modesti producono valori percentuali molto elevati o non definiti. Di conseguenza, la MAPE tende a sovrastimare fortemente l'errore in presenza di target piccoli in valore assoluto e risulta difficile da interpretare, soprattutto su scale normalizzate come lo `z_score`.

Per questi motivi, nel seguito la MAPE viene riportata solo come informazione aggiuntiva, mentre l'analisi delle prestazioni dei modelli si basa principalmente su RMSE, MAE e R^2, che in questo contesto forniscono indicatori più stabili e significativi dell'accuratezza delle predizioni.

3.5 Strategia di validazione

Per valutare le prestazioni dei modelli e limitare il rischio di sovradattamento ai dati disponibili, è stata adottata una strategia di validazione in due passi: un primo confronto tramite

split train/test 70/30 e una successiva validazione incrociata 10-fold sul modello ritenuto più affidabile.

Nel primo passo, il dataset viene suddiviso in un insieme di addestramento (70% delle osservazioni) e un insieme di test (30%), mantenendo fisso il seme del generatore pseudocasuale per rendere riproducibile lo split. Questa suddivisione viene utilizzata per confrontare, in modo coerente, le prestazioni dei tre modelli (Regressione Lineare, Random Forest, Gradient Boosting) sia nella configurazione con feature base (NDVI e albedo) sia nella configurazione con feature estese (NDVI, albedo, indici compositi). Tutti i modelli vedono lo stesso insieme di training e vengono valutati sullo stesso insieme di test, in modo che le differenze nelle metriche (RMSE, MAE, R^2, MAPE) riflettano il comportamento del modello e non variazioni dovute a diversi campionamenti dei dati.

Nel secondo passo, una volta identificato il modello più affidabile (Random Forest con feature estese), viene applicata una validazione incrociata 10-fold per ottenere una stima più robusta della capacità di generalizzazione. Il dataset viene suddiviso in dieci sottoinsiemi (fold) di dimensione simile; a ogni iterazione, nove fold vengono utilizzati per l'addestramento e il decimo per la validazione, ruotando il ruolo dei fold fino a coprire tutte le osservazioni. Per implementare questo schema si utilizza la funzione `cross_val_predict` di `scikit-learn`, che restituisce, per ciascun campione, la predizione ottenuta quando quel campione apparteneva al fold di validazione (predizione *out-of-fold*).

A partire da queste predizioni out-of-fold si calcolano RMSE, MAE, R^2 e MAPE sull'intero dataset. In questo modo ogni osservazione viene usata una sola volta come dato di test, ma tutte contribuiscono alla stima delle metriche. La validazione incrociata 10-fold fornisce quindi una misura più stabile e meno dipendente da un singolo split dei dati rispetto al semplice train/test 70/30, ed è utilizzata in questa tesi per confermare la robustezza delle prestazioni ottenute dal modello Random Forest con feature estese.

Codice e dati

Il codice Python utilizzato per la preparazione dei dati, l'addestramento dei modelli e la produzione delle figure, insieme a un archivio compresso dei dati di input utilizzati in questa tesi, è disponibile in formato open access al seguente repository GitHub:

https://github.com/fabiomalagutti27-droid/tesi-machinelearning

Il repository contiene il notebook principale, gli script di supporto e un file `README` con le istruzioni essenziali per la riproduzione delle analisi.

Capitolo 4

Risultati dei modelli

In questo capitolo vengono presentati e analizzati i risultati ottenuti dai modelli di regressione applicati al dataset TALEA per il Comune di Bologna. A partire dall'impostazione metodologica descritta nel Capitolo 3, si riportano le prestazioni numeriche (RMSE, MAE, R^2, MAPE) e le principali evidenze emerse dal confronto tra le diverse configurazioni di feature e i tre modelli considerati (Regressione Lineare, Random Forest Regressor, Gradient Boosting Regressor).

Nella prima parte vengono mostrati i risultati relativi al *modello base*, che utilizza come variabili esplicative solo l'NDVI medio e l'albedo medio, e si confrontano le prestazioni dei tre algoritmi su questa configurazione minima. Successivamente, si analizza il *modello esteso*, che include anche gli indici compositi `heat_veg_index` e `heat_retention_index`, valutando se e in che misura tali indici migliorano la capacità predittiva del modello e modificano l'importanza relativa delle feature.

In una terza fase vengono presentati i risultati del modello che integra *feature spaziali* basate sull'NDVI di vicinato (medie entro 100, 200 e 500 metri), con l'obiettivo di verificare se l'informazione sul verde circostante alla cella aggiunge valore rispetto al solo NDVI locale. Infine, si riportano gli esiti della validazione incrociata 10-fold applicata al modello considerato più affidabile (Random Forest con feature estese), per fornire una stima più robusta delle prestazioni e discutere la stabilità dei risultati.

Oltre alle metriche aggregate, il capitolo include visualizzazioni a supporto dell'interpretazione: grafici di importanza delle feature, scatter plot tra valori osservati e predetti, istogrammi degli errori e mappe di z_score predetto e dei residui sulla città di Bologna, utili per collegare i risultati numerici al contesto urbano reale.

4.1 Modelli con feature base (NDVI + albedo)

In una prima fase sono stati confrontati i tre modelli di regressione utilizzando solo le due feature di base, `ndvi_mean` e `albedo_mean`, come descritto nel Capitolo 3. Per ciascun modello è stato eseguito uno split train/test 70/30 sullo stesso insieme di dati e sono state calcolate le metriche RMSE, MAE, R^2 e MAPE sul test set.

La Tabella 4.1 riporta i valori ottenuti per la Regressione Lineare, la Random Forest Regressor e il Gradient Boosting Regressor nella configurazione con feature base.

Tabella 4.1: Prestazioni dei modelli di regressione con feature base (NDVI_mean, albedo_mean) sul test set.

Modello	R^2	RMSE	MAE	MAPE (%)
Regressione lineare	0.18784	1.04981	0.80175	343.17120
Random Forest	0.99996	0.00703	0.00080	0.51728
Gradient Boosting	0.99990	0.01157	0.00826	4.34598

Dalla tabella emerge che i due modelli ad alberi (Random Forest e Gradient Boosting) raggiungono valori di R^2 prossimi a 1 e errori (RMSE, MAE) molto contenuti, indicando un'elevata capacità di ricostruire lo `z_score` della LST a partire da NDVI e albedo. La Regressione Lineare, al contrario, presenta un R^2 molto basso e valori di RMSE e MAE di ordini di grandezza maggiori, segnalando che una relazione puramente lineare tra le feature di base e il target non è sufficiente a descrivere la variabilità termica intraurbana nel dataset considerato. Anche la MAPE conferma questo quadro: valori inferiori all'1% per la Random Forest, qualche punto percentuale per il Gradient Boosting e valori dell'ordine di centinaia di punti percentuali per la Regressione Lineare.

Oltre alle metriche aggregate, è stato analizzato il comportamento degli errori per ciascun modello. Le Figure 4.1–4.3 mostrano gli istogrammi dei residui (valore osservato meno valore predetto) per Regressione Lineare, Random Forest e Gradient Boosting, rispettivamente.

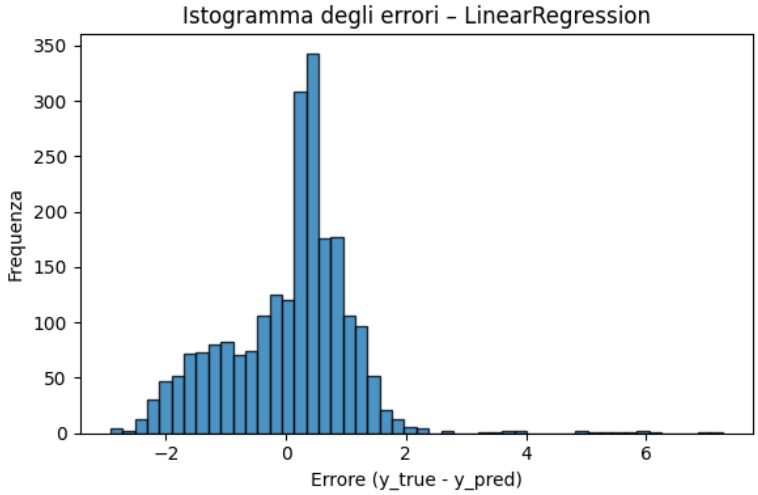


Figura 4.1: Istogramma degli errori (z_score osservato meno z_score predetto) per la Regressione Lineare con feature base.

Nel caso della Regressione Lineare (Figura 4.1), la distribuzione degli errori è molto larga, con residui che si estendono su un intervallo ampio e una concentrazione relativamente debole attorno allo zero. Questo è coerente con i valori elevati di RMSE e MAE, e indica che il modello commette errori significativi sia in eccesso sia in difetto su una parte consistente dei poligoni.

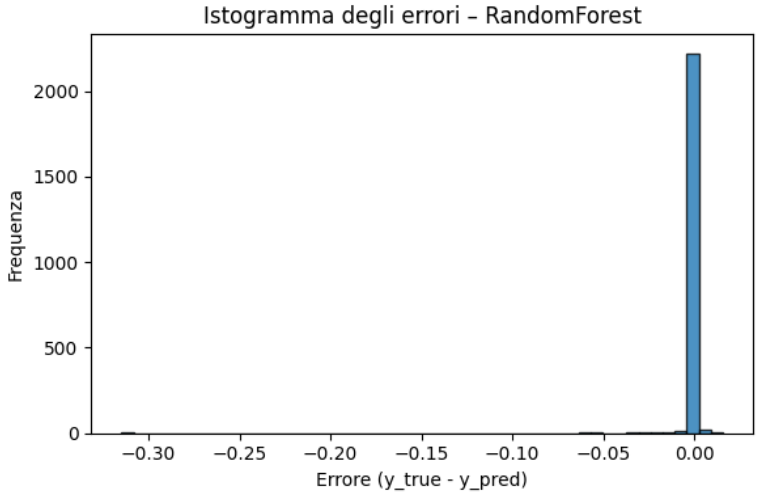


Figura 4.2: Istogramma degli errori (z_score osservato meno z_score predetto) per il modello Random Forest con feature base.

Per la Random Forest (Figura 4.2) l'istogramma è fortemente concentrato attorno allo zero, con code molto corte: la maggior parte dei residui ha modulo estremamente ridotto, in accordo con i valori bassissimi di RMSE e MAE in Tabella 4.1. Questo conferma che il modello è in grado di ricostruire con alta precisione lo `z_score` per quasi tutti i poligoni del test set.

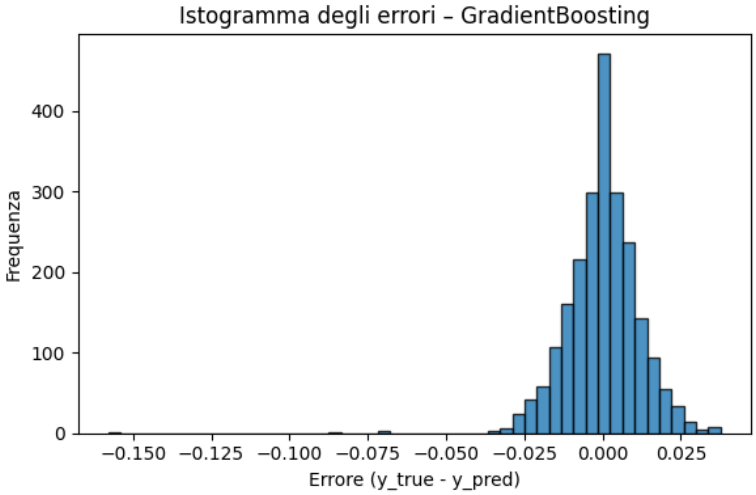


Figura 4.3: Istogramma degli errori (z_score osservato meno z_score predetto) per il modello Gradient Boosting con feature base.

Il Gradient Boosting (Figura 4.3) presenta una distribuzione degli errori più concentrata rispetto alla Regressione Lineare, ma leggermente più ampia rispetto alla Random Forest. I residui sono in media piccoli, ma le code risultano un po' più pronunciate. Il confronto diretto tra i tre istogrammi rende evidente il motivo per cui, nelle analisi successive, ci si concentra principalmente sulla Random Forest: è il modello che produce la distribuzione degli errori più stretta e simmetrica, con la massima parte dei residui vicina a zero.

Per il modello Random Forest con feature base è stata analizzata anche l'importanza relativa delle due variabili in ingresso. Il grafico in Figura 4.4 mostra che `ndvi_mean` e `albedo_mean` hanno importanze quasi bilanciate, entrambe prossime a 0.5. Questo indica che, nella configurazione di base, sia la componente biotica (presenza di vegetazione) sia la componente radiativa (riflettanza delle superfici) contribuiscono in modo comparabile alla spiegazione della variabilità dello `z_score` della LST.

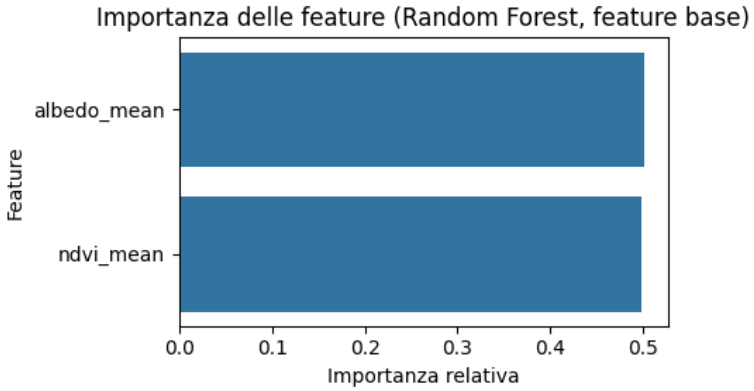


Figura 4.4: Importanza relativa delle feature nel modello Random Forest con feature base (NDVI_mean, albedo_mean).

Per valutare più nel dettaglio la qualità delle predizioni della Random Forest con feature base, è stato analizzato lo scatter plot tra valori osservati e predetti dello `z_score` sul test set, riportato in Figura 4.5. I punti risultano molto vicini alla retta ideale $y = x$, a conferma del fatto che il modello riesce a ricostruire con buona accuratezza tanto le aree relativamente più fredde quanto quelle relativamente più calde.

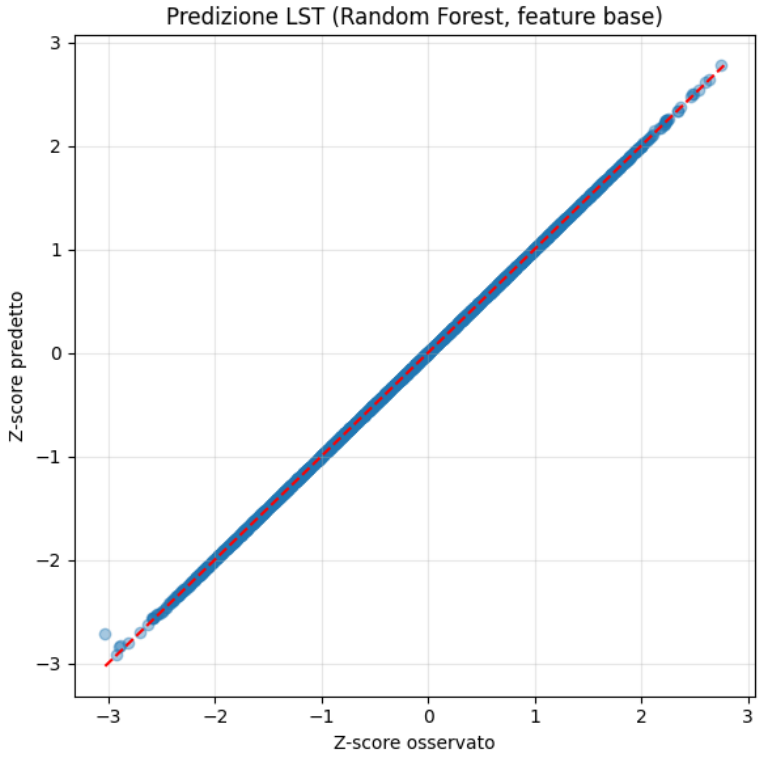


Figura 4.5: Confronto tra z_score osservato e z_score predetto dal modello Random Forest con feature base. La linea tratteggiata rappresenta la retta ideale $y = x$.

Infine, per collegare i risultati numerici al contesto spaziale, sono state prodotte mappe del

valore osservato e della differenza osservato-meno-predetto sul territorio comunale di Bologna. A titolo esemplificativo, la Figura 4.6 mostra la distribuzione spaziale dello `z_score` osservato sul test set, mentre la Figura 4.7 riporta la mappa dei residui per la Random Forest base. La mappa dei residui evidenzia che gli errori sono generalmente piccoli e non mostrano pattern spaziali marcati, suggerendo che il modello cattura in modo efficace la struttura principale della variabilità termica a partire da NDVI e albedo.

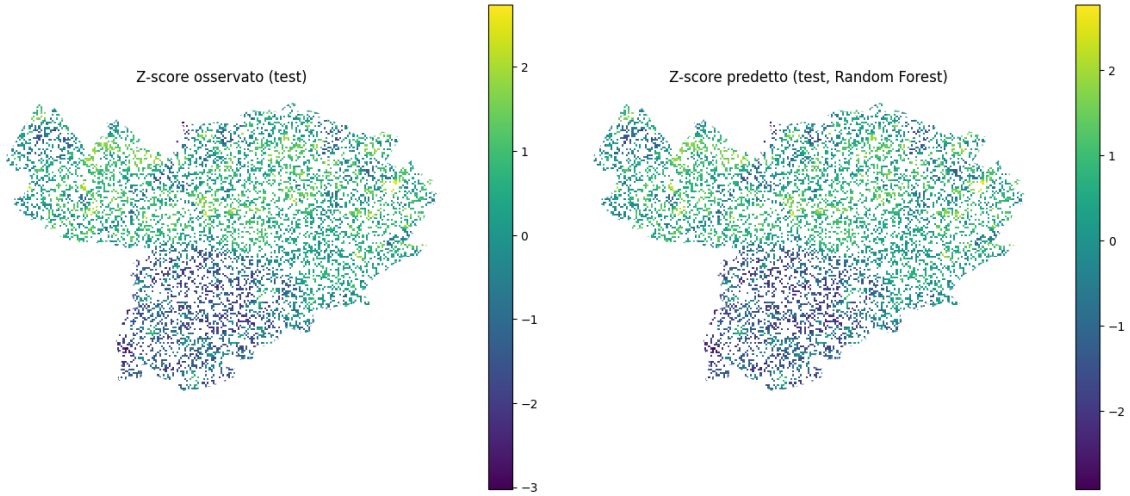


Figura 4.6: Distribuzione spaziale dello z_score osservato sul test set per il modello con feature base.

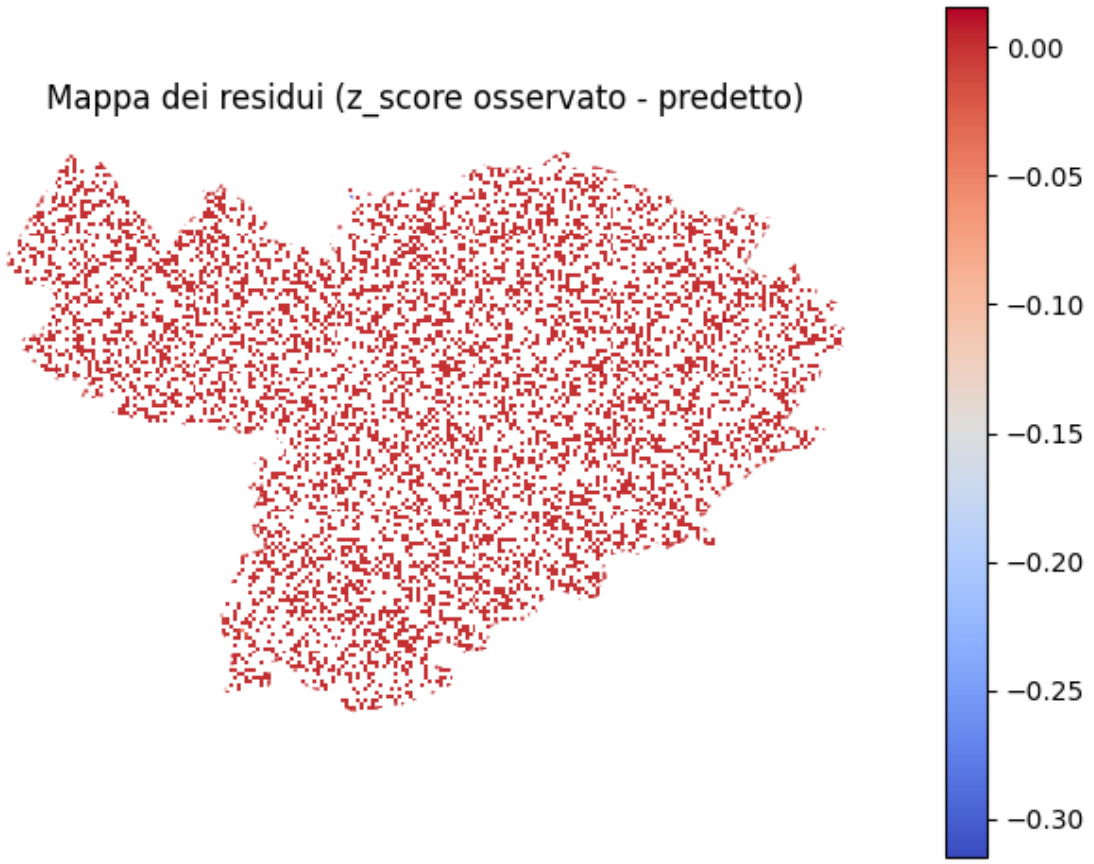


Figura 4.7: Mappa dei residui (z_score osservato meno z_score predetto) per il modello Random Forest con feature base.

4.2 Modelli con feature estese (NDVI + albedo + indici compositi)

In una seconda fase sono stati confrontati i tre modelli di regressione utilizzando la configurazione con feature estese, che include oltre a `ndvi_mean` e `albedo_mean` anche gli indici compositi `heat_veg_index` e `heat_retention_index`. Come nel caso precedente, è stato utilizzato uno split train/test 70/30 fisso e le metriche sono state calcolate sul test set.

La Tabella 4.2 riporta i risultati ottenuti per Regressione Lineare, Random Forest e Gradient Boosting nella configurazione estesa.

Tabella 4.2: Prestazioni dei modelli di regressione con feature estese (NDVI_mean, albedo_mean, heat_veg_index, heat_retention_index) sul test set.

Modello	R^2	RMSE	MAE	MAPE (%)
Regressione lineare	0.68039	0.65857	0.49754	399.73956
Random Forest	0.99999	0.00423	0.00058	0.20304
Gradient Boosting	0.99989	0.01226	0.00838	5.22878

Rispetto al modello con sole feature base, la Random Forest migliora ulteriormente sia l'RMSE sia il R^2, avvicinandosi a una ricostruzione praticamente perfetta dello `z_score` sul test set. Anche il Gradient Boosting mantiene prestazioni molto elevate, con R^2 quasi unitario e errori contenuti, sebbene leggermente peggiori rispetto alla Random Forest. La Regressione Lineare mostra un netto miglioramento rispetto al caso base (aumento di R^2 e riduzione di RMSE e MAE), ma resta comunque molto distante dai modelli ad alberi, confermando che una relazione puramente lineare non è sufficiente a catturare la complessità del legame tra feature estese e target.

Per il modello Random Forest con feature estese è stata analizzata l'importanza relativa delle quattro variabili in ingresso. Il grafico in Figura 4.8 mostra che tutte le feature contribuiscono in modo non trascurabile: `albedo_mean` e `ndvi_mean` risultano le variabili più importanti, seguite da `heat_veg_index` e `heat_retention_index`. Gli indici compositi non sostituiscono NDVI e albedo, ma aggiungono informazione utile affinando la rappresentazione delle condizioni termiche urbane.

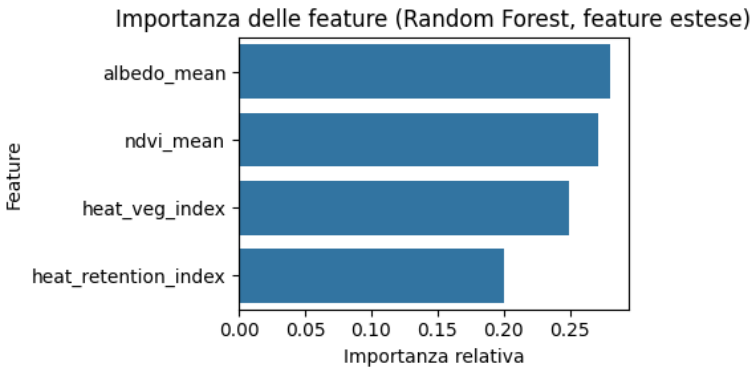


Figura 4.8: Importanza relativa delle feature nel modello Random Forest con feature estese.

La matrice di correlazione tra `ndvi_mean`, `albedo_mean`, `heat_veg_index` e `heat_retention_index`, riportata in Figura 4.9, evidenzia alcuni pattern rilevanti. NDVI e albedo presentano una forte correlazione positiva, coerente con quanto osservato nell'analisi esplorativa. `heat_veg_index` è

fortemente anticorrelato con NDVI e albedo, mentre `heat_retention_index` presenta correlazioni positive moderate con NDVI e albedo e una correlazione negativa moderata con `heat_veg_index`. Le quattro variabili non sono indipendenti, ma forniscono viste parzialmente complementari sulle stesse condizioni fisiche (presenza di vegetazione, riflettanza, accumulo di calore).

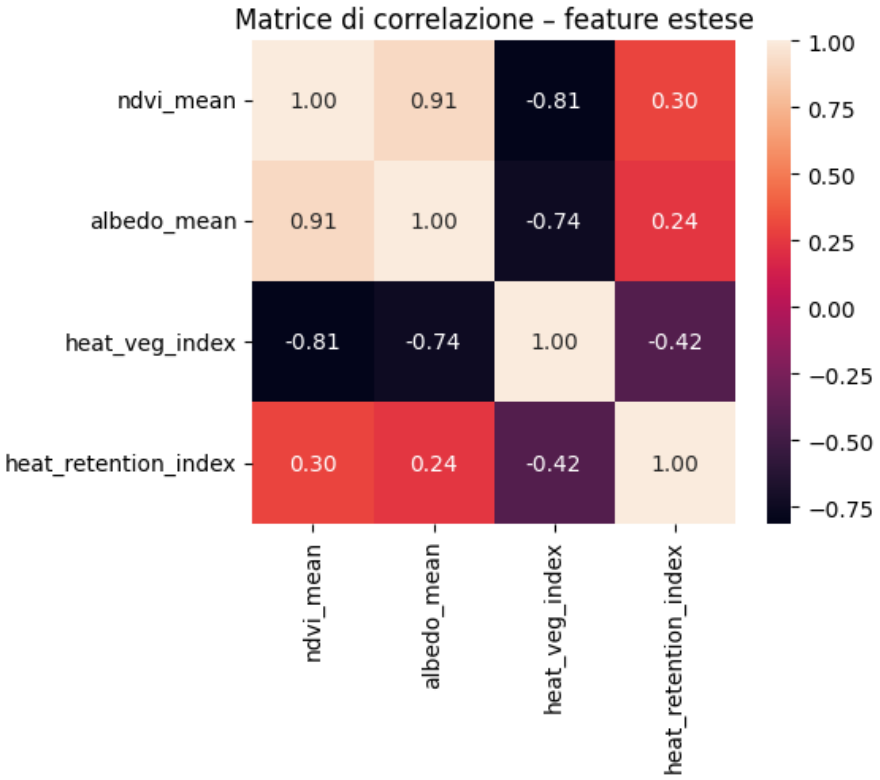


Figura 4.9: Matrice di correlazione tra NDVI_mean, albedo_mean, heat_veg_index e heat_retention_index.

Anche per il modello Random Forest esteso sono stati prodotti grafici di confronto tra valori osservati e predetti e analisi degli errori. Lo scatter plot in Figura 4.10 mette in relazione lo `z_score` osservato e quello predetto sul test set: i punti risultano quasi perfettamente allineati alla retta ideale $y = x$, con una dispersione minima, a conferma dell'elevata accuratezza del modello.

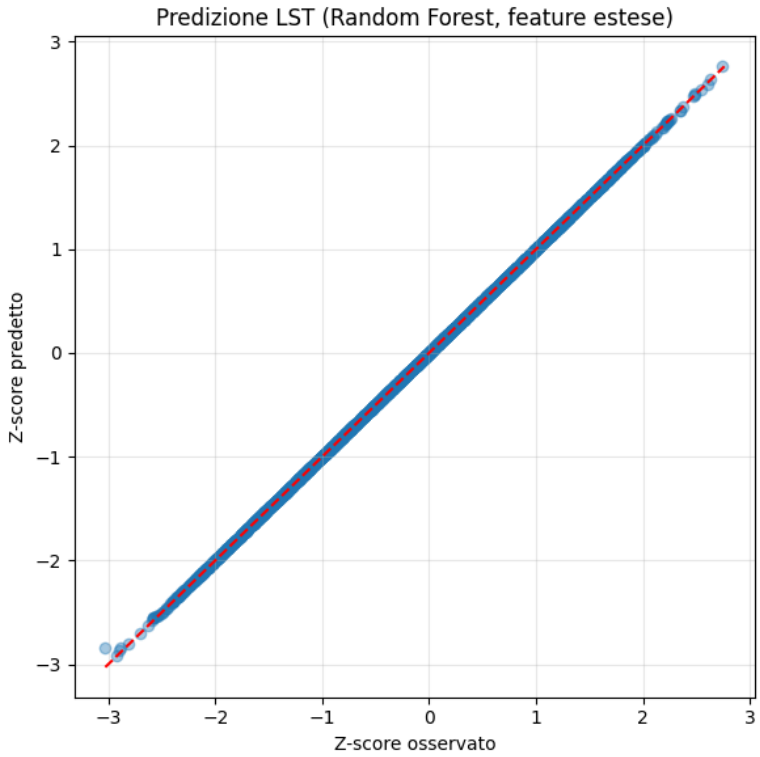


Figura 4.10: Confronto tra z_score osservato e z_score predetto dal modello Random Forest con feature estese. La linea tratteggiata rappresenta la retta ideale $y = x$.

La distribuzione degli errori (osservato meno predetto) per la Random Forest estesa è mostrata in Figura 4.11. L'istogramma è ancora più concentrato attorno allo zero rispetto al caso base, con code estremamente corte, in accordo con la riduzione di RMSE e MAE riportata in Tabella 4.2.

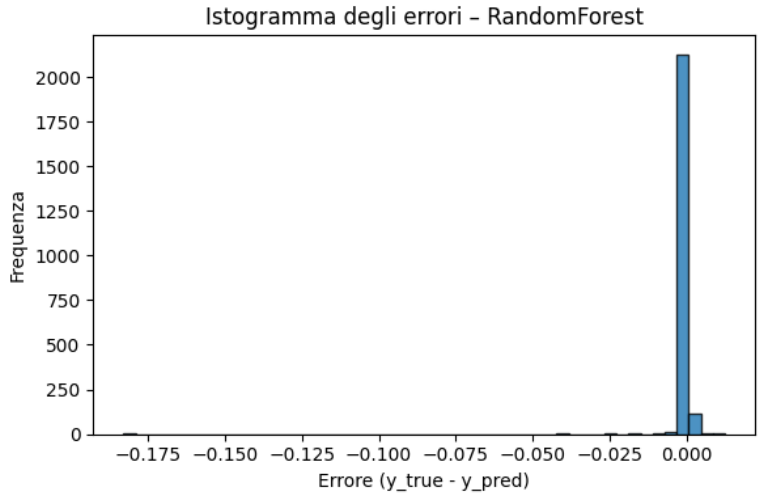


Figura 4.11: Istogramma degli errori (z_score osservato meno z_score predetto) per il modello Random Forest con feature estese.

Per collegare i risultati al contesto spaziale, è stata prodotta anche la distribuzione dello `z_score` osservato (o predetto) sul territorio comunale per il modello esteso (Figura 4.12). La mappa mostra un pattern coerente con quello già osservato nel modello base, confermando che l'introduzione degli indici compositi affina la predizione senza alterare la struttura spaziale principale delle zone più calde e più fredde.

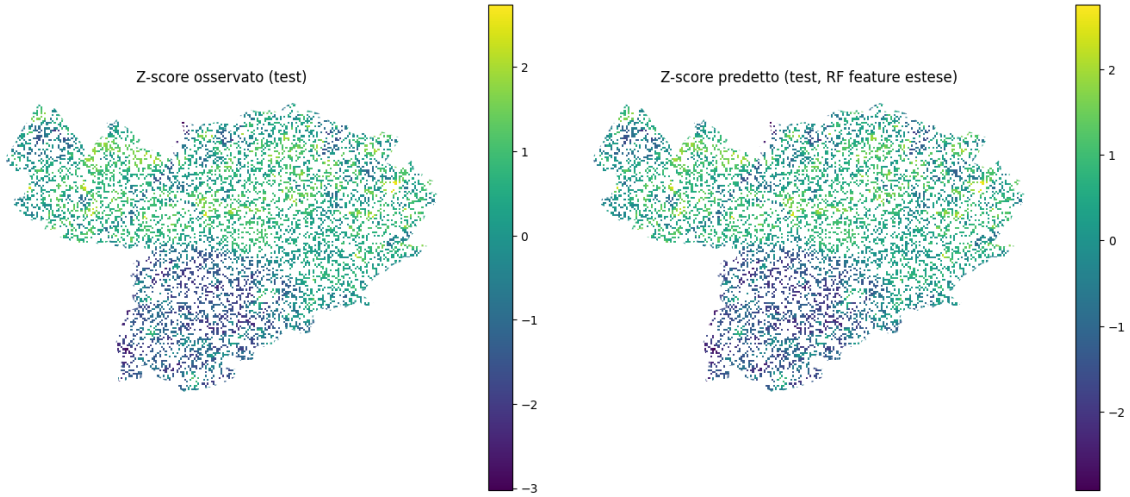


Figura 4.12: Distribuzione spaziale dello z_score (osservato o predetto) per il modello Random Forest con feature estese.

Infine, per visualizzare la distribuzione spaziale delle prestazioni del modello esteso, è stata prodotta la mappa dei residui (Figura 4.13). Gli errori risultano numericamente piccoli e non mostrano pattern spaziali forti: le aree in cui il modello tende a sottostimare o sovrastimare leggermente lo `z_score` sono limitate e distribuite in modo piuttosto omogeneo sulla città, suggerendo che la combinazione di NDVI, albedo e indici compositi cattura in maniera efficace la struttura principale della variabilità termica intraurbana.

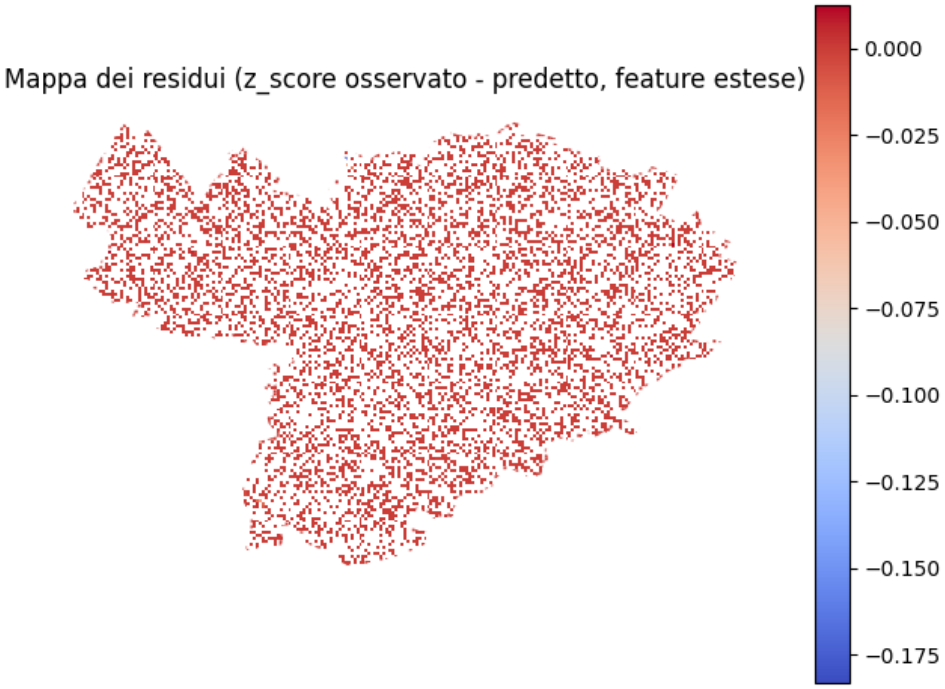


Figura 4.13: Mappa dei residui (z_score osservato meno z_score predetto) per il modello Random Forest con feature estese.

Per mettere in evidenza le poche zone in cui il modello commette errori relativamente più grandi, è stata svolta un'analisi dettagliata sui residui della Random Forest estesa. A partire dai residui sul test set è stato calcolato l'errore assoluto `abs_residuo` e, per aumentarne il contrasto su una scala numerica molto compressa, il suo logaritmo in base 10, `log_abs_residuo`:

$$\texttt{abs_residuo} = |z_\text{true} - z_\text{pred}|, \qquad \texttt{log_abs_residuo} = \log_{10}(\texttt{abs_residuo} + \varepsilon),\ \varepsilon = 10^{-6}.$$

Le statistiche descrittive dell'errore assoluto sono le seguenti:

- media $\approx 5.8 \times 10^{-4}$;
- deviazione standard $\approx 4.2 \times 10^{-3}$;
- primo quartile $\approx 1.2 \times 10^{-4}$;
- mediana $\approx 2.5 \times 10^{-4}$;
- terzo quartile $\approx 4.7 \times 10^{-4}$;
- massimo $\approx 1.83 \times 10^{-1}$.

La grande maggioranza dei poligoni presenta quindi errori assoluti inferiori a 5×10^{-4}, mentre il valore massimo, pur essendo superiore di alcuni ordini di grandezza rispetto alla media, rimane comunque inferiore a 0.2 in unità di `z_score`.

La Figura 4.14 mostra la mappa di `log_abs_residuo` sul test set: la scala logaritmica permette di enfatizzare visivamente le poche celle con errore relativamente maggiore, mantenendo leggibili anche le differenze tra errori molto piccoli.

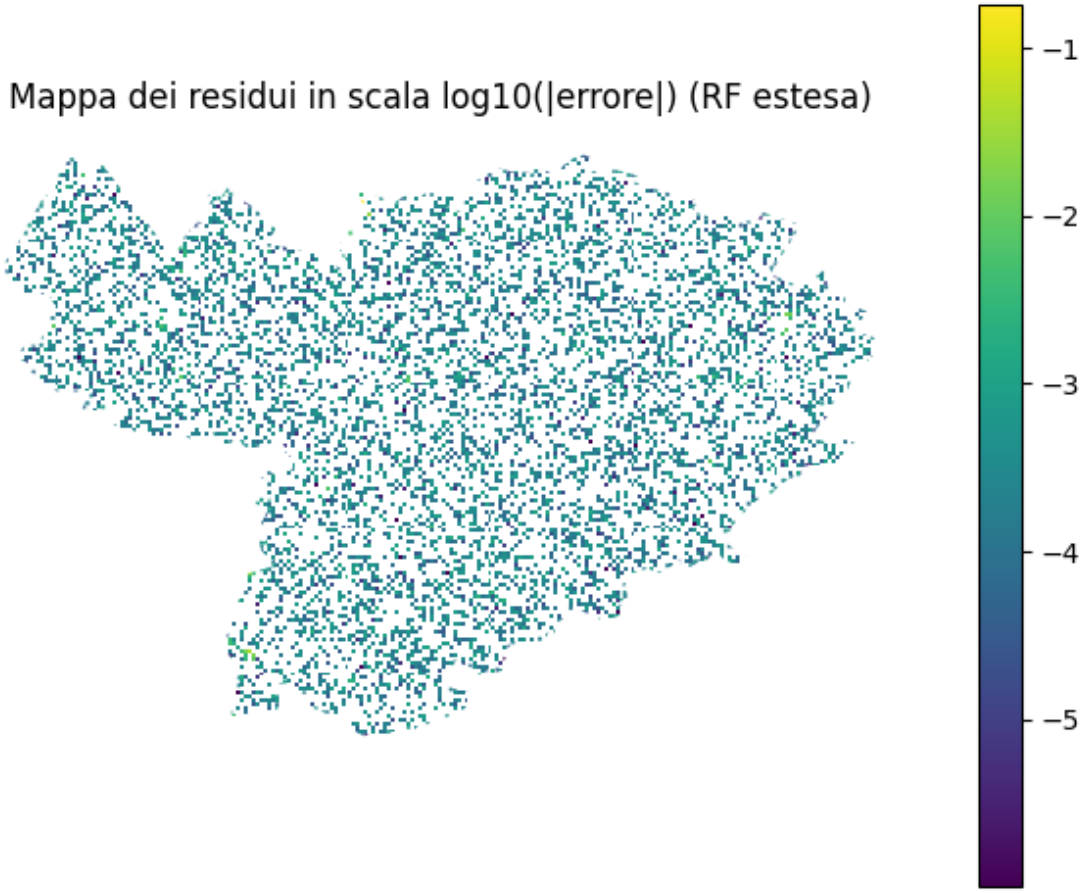


Figura 4.14: Mappa dei residui in scala logaritmica $\log_{10}(|z_\text{true} - z_\text{pred}|)$ per il modello Random Forest con feature estese.

Per identificare in modo esplicito le osservazioni più critiche, sono stati ordinati i poligoni in base all'errore assoluto e selezionate le prime venti celle con `abs_residuo` maggiore. La Tabella 4.3 riporta, per ciascuna di esse, l'identificativo `gid`, il valore osservato `z_true`, il valore predetto `z_pred`, il residuo e l'errore assoluto.

Tabella 4.3: Prime 20 celle del test set con errore assoluto maggiore per la Random Forest con feature estese.

gid	z_true	z_pred	residuo	abs_residuo
4022	-3.028868	-2.845821	-0.183046	0.183046
4011	-2.883801	-2.842022	-0.041779	0.041779
4012	-2.899867	-2.861320	-0.038547	0.038547
3978	-2.582327	-2.556888	-0.025439	0.025439
3979	-2.582799	-2.557679	-0.025120	0.025120
3977	-2.574766	-2.556888	-0.017878	0.017878
4010	-2.817647	-2.801597	-0.016050	0.016050
3980	-2.587997	-2.572373	-0.015624	0.015624
7566	2.745926	2.761305	-0.015379	0.015379
7561	2.603222	2.590698	0.012524	0.012524
7551	2.481309	2.490984	-0.009675	0.009675
7552	2.487452	2.497051	-0.009599	0.009599
7531	2.344748	2.335356	0.009391	0.009391
7499	2.126911	2.135710	-0.008798	0.008798
3975	-2.549722	-2.540999	-0.008723	0.008723
7509	2.184560	2.176614	0.007946	0.007946
3971	-2.530348	-2.522785	-0.007563	0.007563
3973	-2.539799	-2.533987	-0.005812	0.005812
7524	2.261582	2.255815	0.005767	0.005767
7532	2.345220	2.339663	0.005557	0.005557

Si osserva che le celle con errore maggiore corrispondono in gran parte a valori di `z_score` estremi, sia molto negativi (zone relativamente più fredde, con z_score intorno a -3) sia molto positivi (zone relativamente più calde, con z_score superiore a 2). Questo indica che il modello è leggermente meno accurato nelle code della distribuzione, dove la LST normalizzata assume valori più rari e potenzialmente influenzati da fattori locali non esplicitamente modellati (morfologia urbana fine, materiali specifici, traffico, ventilazione, ombreggiamento). Tuttavia, anche in questi casi, lo scostamento massimo rimane dell'ordine di 0.18 in unità di `z_score`, quindi limitato in termini assoluti.

Per visualizzare in modo sintetico la posizione spaziale di queste celle, è stata prodotta una mappa in cui l'intero test set è rappresentato in grigio chiaro, mentre i poligoni con errore

maggiore sono evidenziati in rosso (Figura 4.15). Le celle critiche risultano sparse sul territorio e non formano cluster estesi: questo suggerisce che le deviazioni più grandi sono localizzate e non indicano un bias sistematico del modello su porzioni specifiche della città.



Figura 4.15: Poligoni del test set con errore assoluto maggiore (in rosso) per il modello Random Forest con feature estese; gli altri poligoni del test set sono mostrati in grigio.

4.3 Modello con NDVI di vicinato (100, 200, 500 m)

Per verificare se l'informazione sul verde circostante alla cella potesse migliorare ulteriormente la predizione dello `z_score` della LST, è stato costruito un modello basato su feature di vicinato derivate dall'NDVI.

A partire dal layer vettoriale di `ndvi_mean`, il `GeoDataFrame` è stato proiettato da WGS84 (EPSG:4326) a un sistema di coordinate metriche adatto all'area di Bologna (UTM zona 32N, EPSG:32632), in modo che le distanze fossero espresse in metri e i buffer avessero un significato geometrico corretto. Su questo layer sono stati poi calcolati, per ciascun poligono, tre valori di NDVI medio entro buffer di raggio 100 m, 200 m e 500 m (`ndvi_mean_100m`, `ndvi_mean_200m`, `ndvi_mean_500m`).

Per rendere il calcolo computazionalmente efficiente ed evitare una complessità quadratica nel numero di poligoni, è stato utilizzato l'indice spaziale messo a disposizione da GeoPandas. Per ogni poligono si è proceduto come segue: (i) costruzione del buffer metrico di raggio desiderato, (ii) interrogazione dell'indice spaziale per selezionare solo i candidati che intersecano il riquadro di bounding del buffer, (iii) filtraggio di tali candidati tenendo solo quelli che intersecano effettivamente il buffer, (iv) calcolo della media dei valori `ndvi_mean` dei poligoni così selezionati. Ripetendo questo procedimento per i tre raggi si ottengono, per ciascuna osservazione, gli indici di NDVI di vicinato alle diverse scale considerate.

Su questo dataset arricchito è stato poi addestrato un modello *Random Forest Regressor* con il seguente insieme di feature:

$$\mathbf{x}_i = \big(\texttt{ndvi_mean}, \texttt{albedo_mean}, \texttt{ndvi_mean_100m}, \texttt{ndvi_mean_200m}, \texttt{ndvi_mean_500m}\big)_i.$$

Le metriche ottenute sul test set (split 70/30) sono riportate in Tabella 4.4.

Tabella 4.4: Prestazioni della Random Forest con NDVI locale e NDVI di vicinato (100, 200, 500 m) sul test set.

Modello	R^2	RMSE	MAE	MAPE (%)
Random Forest (NDVI, albedo, NDVI vicinato)	0.99997	0.00680	0.00090	0.31839

Le prestazioni sono molto simili a quelle della Random Forest con sole feature base: il valore di R^2 rimane prossimo a 1, mentre RMSE e MAE restano dell'ordine di pochi millesimi in valore assoluto. Questo indica che, dal punto di vista delle metriche globali, l'aggiunta dell'NDVI di vicinato non modifica in modo sostanziale la capacità predittiva del modello.

L'analisi dell'importanza delle feature fornisce un'indicazione più chiara del ruolo delle nuove variabili. Il grafico in Figura 4.16 mostra le importanze relative stimate dalla Random Forest: quasi tutto il peso è concentrato su `albedo_mean` e `ndvi_mean`, con valori rispettivamente pari a circa 0.51 e 0.49. Le tre feature di vicinato `ndvi_mean_100m`, `ndvi_mean_200m` e `ndvi_mean_500m` hanno importanza praticamente nulla (dell'ordine di 10^{-6}).

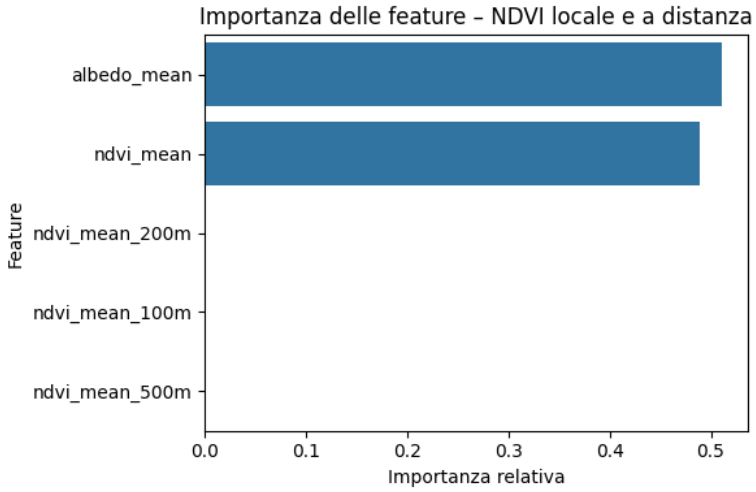


Figura 4.16: Importanza relativa delle feature nel modello Random Forest con NDVI locale e NDVI di vicinato (100, 200, 500 m).

In sintesi, nel dataset TALEA utilizzato in questa tesi l'NDVI locale della cella sembra catturare già l'informazione essenziale sulla presenza di verde alla scala spaziale rilevante per la LST, mentre le medie di NDVI entro 100–500 m, così come definite, risultano ridondanti rispetto all'NDVI della cella. Le feature di vicinato non portano un miglioramento misurabile delle metriche e non vengono selezionate dal modello come variabili importanti. Questo non esclude che, in altri contesti o con una diversa definizione di feature spaziali, il verde di vicinato possa avere un ruolo più marcato, ma nel caso specifico analizzato qui la sua influenza risulta trascurabile rispetto a NDVI e albedo locali.

4.4 Validazione incrociata 10-fold della Random Forest estesa

Per ottenere una stima più robusta della capacità di generalizzazione del modello considerato più affidabile, la Random Forest con feature estese (NDVI, albedo, indici compositi), è stata applicata una validazione incrociata 10-fold, come descritto nel Capitolo 3. In questo schema,

ogni osservazione viene predetta esattamente una volta come dato di test (*out-of-fold*), mentre nelle restanti iterazioni contribuisce all'addestramento del modello.

A partire dalle predizioni out-of-fold restituite dalla funzione `cross_val_predict`, sono state calcolate le metriche globali RMSE, MAE, R^2 e MAPE sull'intero dataset. I valori ottenuti sono riportati in Tabella 4.5.

Tabella 4.5: Metriche globali della validazione incrociata 10-fold per la Random Forest con feature estese.

Modello	RMSE (10-fold)	MAE (10-fold)	R^2 (10-fold)	MAPE (10-fold)
Random Forest (feature estese)	0.04020	0.00131	0.99885	50.33516%

I risultati confermano l'elevata qualità del modello anche in un contesto di validazione più severo rispetto al semplice split train/test. Il valore di R^2 rimane molto vicino a 1 e l'RMSE resta contenuto, indicando che la Random Forest con feature estese è in grado di spiegare quasi tutta la variabilità dello `z_score` sull'intero dataset, senza dipendere da uno specifico partizionamento dei dati. Il MAE è molto basso, dell'ordine di 10^{-3}, il che implica che, in media, lo scostamento tra valore osservato e predetto è numericamente minimo per ciascun poligono.

La MAPE calcolata in 10-fold risulta invece elevata (circa 50%), in apparente contrasto con le altre metriche. Questo comportamento è coerente con la natura del target: trattandosi di uno `z_score` centrato attorno a zero, una parte consistente delle osservazioni ha valori molto piccoli in valore assoluto. In queste condizioni anche errori assoluti molto piccoli, quando divisi per un denominatore vicino a zero, producono valori percentuali elevati e rendono la MAPE una metrica poco informativa. Per questo motivo, nella valutazione complessiva del modello si fa principalmente riferimento a RMSE, MAE e R^2, mentre la MAPE viene interpretata con cautela.

La distribuzione degli errori out-of-fold è rappresentata nell'istogramma di Figura 4.17, costruito utilizzando tutte le predizioni della validazione incrociata 10-fold. Anche in questo caso gli errori risultano fortemente concentrati attorno allo zero, con code molto corte, a conferma visiva del fatto che la maggior parte delle predizioni della Random Forest estesa si discosta di pochissimo dai valori osservati e che le buone prestazioni osservate sullo split 70/30 non sono dovute a una particolare suddivisione del dataset ma riflettono una reale stabilità del modello.

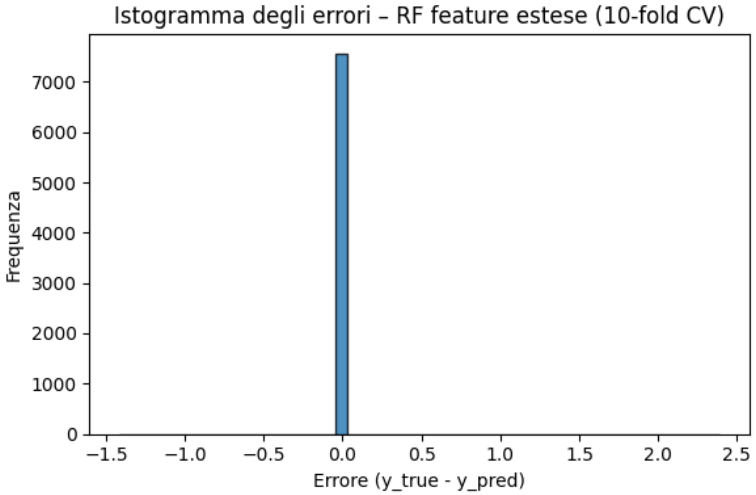


Figura 4.17: Istogramma degli errori out-of-fold (z_score osservato meno z_score predetto) per la Random Forest con feature estese in validazione incrociata 10-fold.

Capitolo 5

Discussione e interpretazione nel contesto urbano

In questo capitolo i risultati quantitativi presentati nel Capitolo 4 vengono riletti in chiave interpretativa, mettendo in relazione il comportamento dei modelli di machine learning con i meccanismi fisici che regolano la temperatura superficiale urbana e con le caratteristiche del caso di studio di Bologna.

L'obiettivo non è introdurre nuove elaborazioni, ma discutere in modo critico cosa significano, dal punto di vista fisico e urbano, le prestazioni quasi perfette ottenute dai modelli ad alberi e la forte capacità esplicativa di pochi indici satellitari (NDVI, albedo e indici compositi). In particolare, il capitolo approfondisce tre aspetti: (i) perché Random Forest e Gradient Boosting superano nettamente la regressione lineare nella predizione dello `z_score` della LST, (ii) quale ruolo effettivo hanno NDVI, albedo e gli indici compositi nella spiegazione della variabilità termica intraurbana, (iii) perché le feature di NDVI di vicinato (100–500 m) risultano di fatto irrilevanti nel dataset TALEA considerato.

Successivamente, la discussione si sposta su una lettura spaziale dei risultati: le mappe di z_score predetto e dei residui vengono utilizzate per collegare i pattern emersi dai modelli alle diverse tipologie di tessuto urbano presenti a Bologna (centro storico denso, quartieri residenziali, aree industriali, zone verdi). Particolare attenzione è dedicata alle poche celle in cui il modello commette errori relativi più grandi, che possono suggerire l'influenza di fattori non esplicitamente modellati (morfologia urbana fine, materiali specifici, traffico, ventilazione locale, ombreggiamento).

Il capitolo si chiude con una riflessione sui principali limiti del lavoro: l'uso dello `z_score` come target invece della LST in unità fisiche, la focalizzazione su un singolo periodo (estate

2024) e su una sola città, la mancanza di variabili urbanistiche esplicite e la possibile presenza di *data leakage strutturale* dovuto al modo in cui il dataset TALEA è costruito. Questi elementi sono importanti per contestualizzare correttamente le prestazioni dei modelli e per preparare il terreno agli spunti di sviluppo futuro discussi nel Capitolo 6.

5.1 Perché i modelli ad alberi superano la regressione lineare

I risultati presentati nel Capitolo 4 mostrano in modo chiaro che i modelli ad alberi (Random Forest e Gradient Boosting) superano di gran lunga la Regressione Lineare in termini di capacità predittiva, sia nella configurazione con sole feature base sia in quella con feature estese. Questa differenza non è solo numerica, ma riflette il diverso modo in cui i modelli rappresentano la relazione tra variabili esplicative e target.

La relazione tra `z_score` della LST, NDVI, albedo e indici compositi è, in generale, non lineare e caratterizzata da possibili interazioni. Ad esempio, l'effetto della vegetazione sulla temperatura superficiale può dipendere dal tipo di materiali presenti, così come l'impatto dell'albedo può variare in funzione del contesto urbano locale. In altre parole, non è ragionevole assumere che l'incremento di NDVI o di albedo produca sempre la stessa variazione di `z_score`, indipendentemente dai valori delle altre variabili.

La Regressione Lineare, per costruzione, impone una forma funzionale semplice:

$$z_\text{pred} = \beta_0 + \beta_1\,\texttt{ndvi_mean} + \beta_2\,\texttt{albedo_mean} + \dots$$

e considera solo combinazioni lineari delle feature (a meno di introdurre manualmente termini di interazione o trasformazioni non lineari). In assenza di un forte lavoro di feature engineering, questa struttura non è in grado di riprodurre fedelmente legami complessi, con soglie, saturazioni o effetti combinati tra indici. Questo spiega i valori relativamente bassi di R^2 e gli errori elevati osservati per la Regressione Lineare, sia nel modello base sia in quello esteso.

Random Forest e Gradient Boosting, al contrario, sono modelli ad alberi che costruiscono in modo automatico partizioni dello spazio delle feature e combinazioni non lineari delle variabili. Una Random Forest media le predizioni di molti alberi decisionali addestrati su sottoinsiemi diversi dei dati, mentre il Gradient Boosting costruisce sequenzialmente alberi che correggono gli errori dei precedenti. In entrambi i casi, il modello può rappresentare funzioni a tratti costanti o quasi costanti, con soglie su NDVI, albedo e sugli indici compositi, e includere implicitamente

interazioni tra feature (ad esempio, regole del tipo "se NDVI è alto *e* albedo è alto, allora lo `z_score` è basso").

Nel dataset TALEA utilizzato in questa tesi, la combinazione di NDVI, albedo e indici compositi contiene una struttura regolare e altamente informativa rispetto allo `z_score`. I modelli ad alberi riescono a sfruttare questa struttura catturando relazioni non lineari e interazioni tra le variabili, ottenendo così valori di R^2 prossimi a 1 e errori molto bassi. La Regressione Lineare, vincolata a una relazione globale semplice, non riesce a rappresentare con la stessa efficacia la complessità del fenomeno e rimane nettamente indietro in termini di prestazioni. In questo senso, il confronto tra modelli conferma sperimentalmente che, per il problema considerato, una classe di modelli flessibile come gli ensemble di alberi è più adatta di un modello lineare standard.

5.2 Ruolo fisico di NDVI, albedo e indici compositi

I risultati ottenuti nei Capitoli 3 e 4 mostrano che una parte molto consistente della variabilità dello `z_score` della LST può essere spiegata a partire da pochi indici satellitari: NDVI e albedo, eventualmente affiancati da `heat_veg_index` e `heat_retention_index`. Dal punto di vista fisico, questo è coerente con l'idea che la distribuzione delle temperature superficiali in ambiente urbano sia governata in larga misura da due componenti principali: la presenza di vegetazione e le proprietà radiative dei materiali.

L'NDVI (`ndvi_mean`) è una misura indiretta della quantità e "qualità" della copertura vegetale. Valori elevati di NDVI indicano aree con vegetazione attiva, in grado di raffreddare la superficie tramite evapotraspirazione e ombreggiamento. L'albedo (`albedo_mean`) descrive invece la frazione di radiazione solare riflessa dalle superfici: materiali chiari e riflettenti tendono a riscaldarsi meno, mentre superfici scure con albedo basso assorbono più energia e raggiungono temperature superficiali maggiori. Il fatto che, nei modelli base, NDVI e albedo emergano con importanze quasi bilanciate e che la Random Forest raggiunga valori di R^2 prossimi a 1 indica che la combinazione di un indice "biotico" (NDVI) e di un indice "radiativo" (albedo) è sufficiente a catturare la maggior parte della variabilità termica intraurbana nel dataset considerato.

Gli indici compositi `heat_veg_index` e `heat_retention_index` possono essere interpretati come un affinamento di questa descrizione di base. `heat_veg_index` sintetizza l'effetto mitigante della vegetazione rispetto alle condizioni termiche locali, combinando in modo mirato informazione legata alla copertura verde. `heat_retention_index` rappresenta invece la tendenza delle superfici urbane ad accumulare e rilasciare calore nel tempo, collegandosi alla presenza

di materiali con elevata capacità termica e alle configurazioni morfologiche che favoriscono l'accumulo di energia. Nel modello Random Forest esteso, questi indici assumono importanze non trascurabili, pur rimanendo leggermente inferiori a quelle di NDVI e albedo: dal punto di vista delle prestazioni, l'incremento rispetto al modello base è moderato ma sistematico (ulteriore riduzione di RMSE e lieve crescita di R^2). In pratica, NDVI e albedo spiegano la struttura principale della LST, mentre `heat_veg_index` e `heat_retention_index` contribuiscono a rifinire la stima in contesti in cui la sola coppia NDVI–albedo non è sufficiente a descrivere tutti i dettagli.

La qualità dei risultati ottenuti suggerisce anche una buona coerenza interna del dataset TALEA. Il fatto che un modello relativamente standard come la Random Forest, alimentato da un numero limitato di feature derivanti da immagini Landsat, riesca a ricostruire con grande accuratezza lo `z_score` della LST indica che gli indici sono stati calcolati in modo consistente e che le relazioni fisiche tra vegetazione, riflettanza e temperatura sono rappresentate in maniera stabile nelle varie porzioni della città. Questo aspetto va tenuto presente nell'interpretazione: da un lato, le prestazioni molto elevate riflettono l'effettiva forza del legame fisico tra indici satellitari e LST; dall'altro, possono essere in parte favorite dal modo in cui gli stessi indici e lo `z_score` sono stati costruiti all'interno del workflow TALEA, tema che viene ripreso nella discussione dei limiti del lavoro.

5.3 Irrelevanza delle feature NDVI a distanza nel caso specifico

L'esperimento con le feature di vicinato basate sull'NDVI (medie entro 100, 200 e 500 m) mostra che, nel dataset TALEA considerato, queste variabili risultano di fatto irrilevanti per il modello. Dal punto di vista numerico, la Random Forest che utilizza come input `ndvi_mean`, `albedo_mean` e le tre feature `ndvi_mean_100m`, `ndvi_mean_200m`, `ndvi_mean_500m` ottiene metriche quasi identiche a quelle del modello con sole feature base. L'analisi delle importanze conferma questo risultato: quasi tutto il peso è concentrato su `albedo_mean` e `ndvi_mean`, mentre le tre feature di vicinato hanno importanza dell'ordine di 10^{-6}.

Una prima interpretazione è che l'NDVI locale della cella (`ndvi_mean`) catturi già l'informazione essenziale sulla presenza di verde alla scala spaziale più rilevante per la LST nel dataset TALEA. Poiché le celle rappresentano porzioni relativamente piccole e omogenee di territorio, la media di NDVI sulla geometria elementare potrebbe essere sufficiente a riassumere la quanti-

tà di vegetazione che effettivamente controlla la temperatura superficiale, rendendo ridondante l'aggiunta di medie calcolate in buffer di raggio 100–500 m.

Una seconda possibile spiegazione riguarda la scelta delle scale spaziali: i buffer di 100, 200 e 500 m possono non essere la "finestra" più sensibile alla LST nella configurazione specifica del dataset (risoluzione, definizione dei poligoni, modalità di calcolo degli indici). In altre parole, è possibile che l'effetto del verde di vicinato si manifesti su scale diverse, oppure che, ai raggi scelti, le medie di NDVI siano fortemente correlate con l'NDVI locale e quindi non aggiungano informazione realmente nuova al modello.

Questi risultati non vanno interpretati come un'evidenza del fatto che il verde di vicinato sia poco importante nella realtà fisica del clima urbano. Indicano semplicemente che, nel caso specifico analizzato (Bologna, estate 2024, dataset TALEA e definizione adottata delle feature), il modello non trae beneficio dall'inclusione di `ndvi_mean_100m`, `ndvi_mean_200m` e `ndvi_mean_500m`. In altri contesti, con risoluzioni diverse, con una diversa definizione dei buffer o includendo esplicitamente variabili urbanistiche (densità edilizia, altezza degli edifici, distanza da parchi), l'informazione di vicinato potrebbe assumere un ruolo più marcato. Nel perimetro di questa tesi, però, la variazione di LST è spiegata quasi interamente da NDVI e albedo locali, e il contributo delle feature di NDVI a distanza risulta trascurabile.

5.4 Lettura spaziale dei risultati su Bologna

Le mappe prodotte nel Capitolo 4 permettono di collegare i risultati dei modelli al contesto urbano reale di Bologna. La distribuzione spaziale dello `z_score` predetto (o osservato) dalla Random Forest estesa mostra pattern coerenti con quanto atteso in una città della Pianura Padana: alcune porzioni del territorio comunale presentano valori marcatamente positivi (aree relativamente più calde), mentre altre si collocano stabilmente nella parte negativa della distribuzione (aree relativamente più fresche).

Per rendere evidente il legame tra temperatura superficiale e copertura vegetale, in Figura 5.1 sono mostrate affiancate la mappa dello `z_score` della LST e la mappa dell'NDVI medio sul territorio comunale. In questo modo il confronto visivo tra le due distribuzioni è immediato.

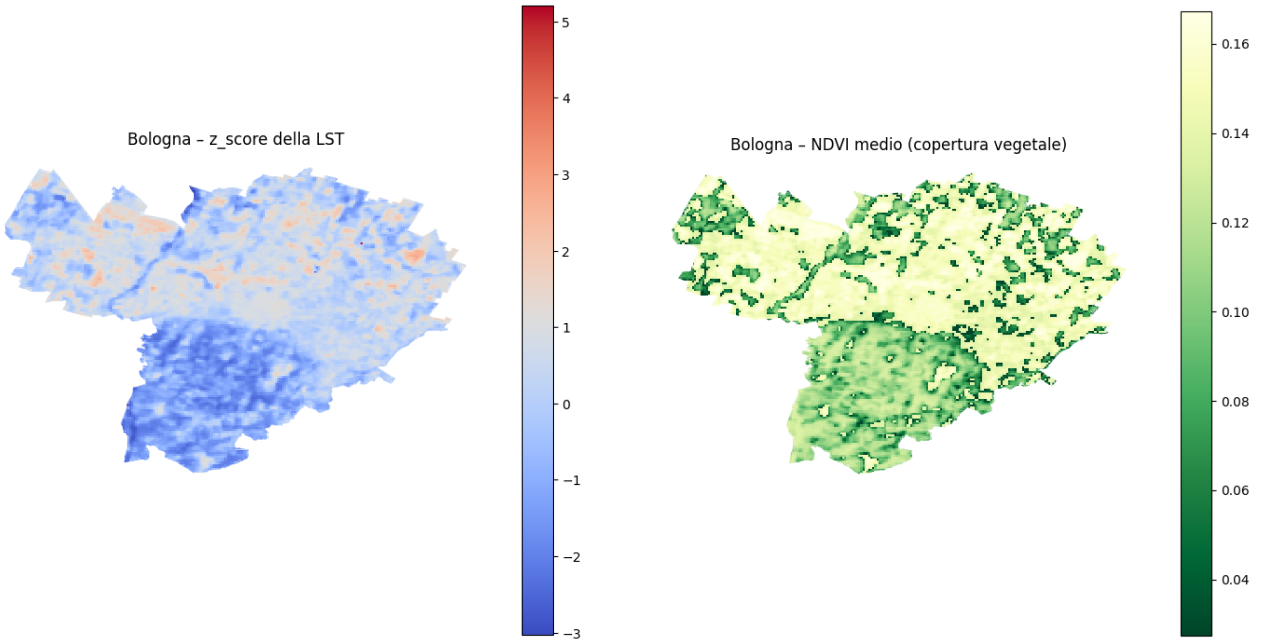


Figura 5.1: Confronto tra distribuzione spaziale dello `z_score` della LST (sinistra, valori più alti = aree relativamente più calde) e mappa dell'NDVI medio sul territorio comunale di Bologna.

Per completezza, la Figura 5.2 mostra la distribuzione spaziale dell'albedo media. Le zone con albedo più elevata tendono a coincidere con aree meno vegetate e con forte presenza di superfici artificiali, mentre i valori più bassi si osservano in corrispondenza di aree verdi o superfici meno riflettenti, coerentemente con il ruolo dell'albedo nella modulazione della temperatura superficiale.

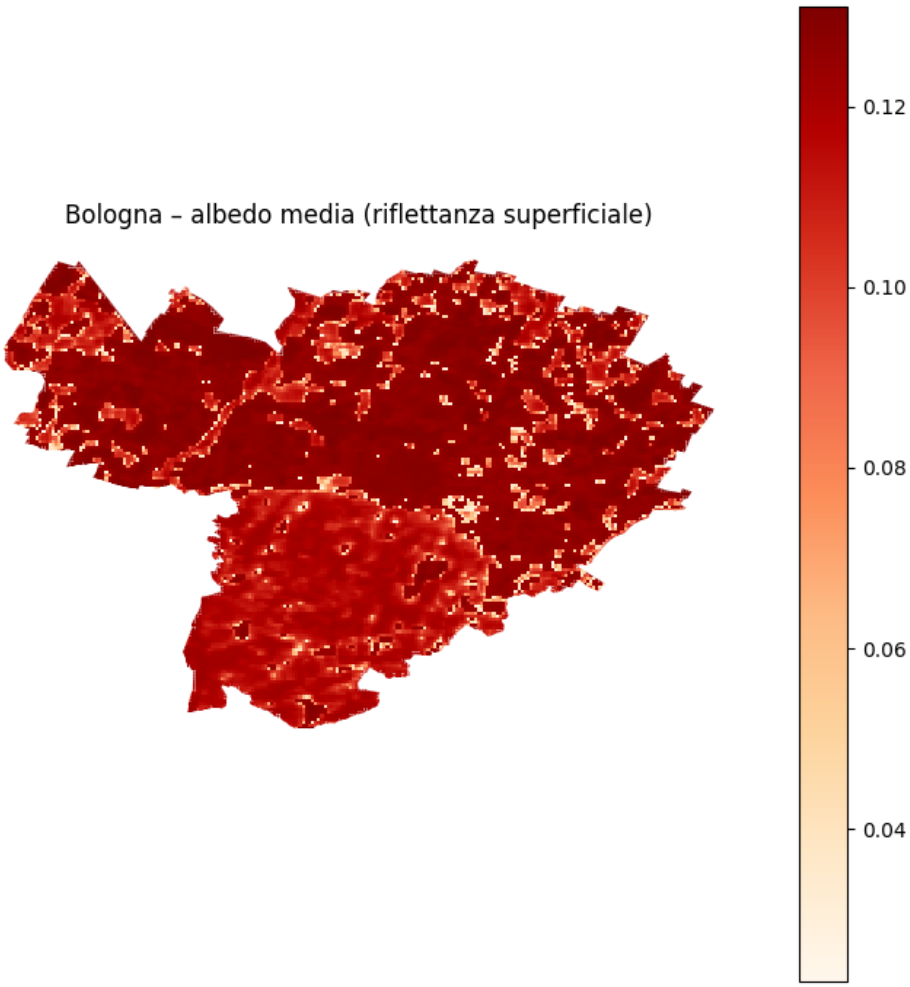


Figura 5.2: Distribuzione spaziale dell'albedo media sul territorio comunale di Bologna.

In maniera qualitativa si osserva che le zone caratterizzate da tessuti edilizi densi, presenza limitata di vegetazione e alta concentrazione di superfici impermeabili tendono ad associarsi a valori di `z_score` più elevati e, contemporaneamente, a valori di NDVI più bassi. Rientrano in questa categoria il centro storico compatto e alcune aree industriali e commerciali, dove capannoni, parcheggi e infrastrutture producono condizioni favorevoli all'accumulo di calore. Al contrario, le aree con maggiore presenza di verde urbano (parchi, fasce alberate) o con tessuti meno densi e più permeabili mostrano in genere valori di NDVI più alti e valori di `z_score` più bassi, corrispondenti a temperature superficiali relativamente più contenute.

La transizione tra quartieri densi, comparti industriali e zone verdi si riflette in graduali variazioni spaziali sia dell'NDVI sia dello `z_score`, che il modello Random Forest esteso riesce a riprodurre con buona fedeltà. Le mappe dei residui discusse nel Capitolo 4 mostrano che gli errori sono numericamente piccoli nella quasi totalità dei poligoni e non formano pattern spaziali marcati, a conferma del fatto che la combinazione di NDVI, albedo e indici compositi cattura in modo efficace la struttura principale della variabilità termica.

Le poche celle con errore relativamente più grande, evidenziate anche dalla mappa in scala logaritmica dell'errore assoluto e dalla selezione dei poligoni "peggiori", tendono a collocarsi in aree particolari, spesso in prossimità di transizioni nette tra tipi di tessuto urbano o in contesti locali complessi. In questi punti è plausibile che entrino in gioco fattori non esplicitamente modellati: morfologia urbana fine (altezza e disposizione degli edifici), materiali specifici delle superfici, traffico veicolare, condizioni locali di ventilazione o ombreggiamento, presenza di elementi infrastrutturali particolari. Nel complesso, tuttavia, l'entità assoluta degli errori rimane ridotta, e la struttura spaziale dei residui conferma la buona capacità del modello di rappresentare il campo termico urbano di Bologna a partire dagli indici forniti dal progetto TALEA.

5.5 Limiti del lavoro

Nonostante i risultati molto buoni ottenuti dai modelli, il lavoro presenta alcuni limiti che è importante esplicitare per contestualizzare correttamente le conclusioni.

Un primo aspetto riguarda la scelta del target. In questa tesi si è utilizzato lo `z_score` della LST e non la temperatura superficiale in unità fisiche (ad esempio °C o K). Questa scelta è coerente con il dataset TALEA, che fornisce direttamente la versione normalizzata della LST e agevola il confronto relativo tra aree più calde o più fredde rispetto alla media urbana. Dal punto di vista interpretativo, però, lo `z_score` è meno immediato: i risultati non possono essere letti direttamente in termini di gradi di differenza, ma solo come scostamenti in deviazioni standard. Ciò rende le conclusioni leggermente meno intuitive per applicazioni operative che richiedono valori termici assoluti.

Un secondo limite è legato al dominio temporale e spaziale dell'analisi. Tutti i modelli sono stati addestrati e valutati su dati relativi a un singolo periodo (estate 2024) e a una sola città (Bologna). Di conseguenza, le prestazioni riportate descrivono la capacità del modello di rappresentare la variabilità termica intraurbana in questo contesto specifico, ma non permettono di trarre conclusioni dirette sulla robustezza temporale (altre stagioni o anni) o sulla trasferibilità del modello ad altre città con morfologia, clima e struttura urbana differenti.

Dal punto di vista delle feature, il lavoro utilizza esclusivamente indici derivati da dati satellitari (NDVI, albedo, indici compositi e NDVI di vicinato), senza includere variabili urbanistiche esplicite come densità edilizia, altezza media degli edifici, distanza da parchi, tipologia d'uso del suolo o indicatori di traffico. Questo approccio ha il vantaggio di mantenere il modello relativamente semplice e interamente basato su layer remoti, ma limita la capacità di interpretare i

residui in termini di fattori urbanistici specifici e potrebbe trascurare porzioni della variabilità termica non spiegabili dai soli indici satellitari.

Infine, esiste una possibile forma di *data leakage strutturale* legata al modo in cui il dataset TALEA è costruito. È plausibile che lo `z_score` della LST e gli indici derivati (in particolare NDVI e albedo) siano collegati non solo fisicamente, ma anche attraverso le scelte di preprocessing e combinazione effettuate nel workflow di generazione dei prodotti. In altre parole, parte della relazione tra target e feature potrebbe essere implicitamente incorporata già nella fase di costruzione del dataset. Questo può contribuire a spiegare perché i modelli ad alberi ottengono prestazioni quasi perfette (valori di R^2 prossimi a 1 e errori molto bassi). Il fenomeno non invalida l'utilità del modello come strumento descrittivo e predittivo nel contesto TALEA, ma va tenuto presente nell'interpretazione: le metriche elevate riflettono sia la forza del legame fisico tra vegetazione, riflettanza e temperatura superficiale, sia la coerenza interna (e la possibile ridondanza) del dataset utilizzato.

Capitolo 6

Conclusioni e sviluppi futuri

In questo capitolo vengono sintetizzati i principali risultati del lavoro svolto e discusse le loro implicazioni nel contesto della modellazione della temperatura superficiale urbana a partire da indici satellitari. L'obiettivo è duplice: da un lato, riassumere in modo compatto ciò che emerge dai capitoli precedenti in termini di prestazioni dei modelli, ruolo delle feature e interpretazione fisica dei risultati; dall'altro, evidenziare come quanto ottenuto possa essere utilizzato in pratica e quali direzioni di estensione appaiono più promettenti.

Nella Sezione 6.1 viene presentata una sintesi dei risultati principali, con particolare attenzione al comportamento della Random Forest con feature estese e al contributo di NDVI, albedo e indici compositi nella spiegazione della variabilità termica intraurbana. La Sezione 6.2 discute alcune implicazioni operative, ovvero come un modello di questo tipo possa essere impiegato come strumento di supporto per analisi e decisioni sulla città. Infine, la Sezione 6.3 propone possibili sviluppi futuri, sia sul piano dell'arricchimento del set di feature e della generalizzazione temporale e spaziale dei modelli, sia sul piano dell'integrazione in strumenti applicativi destinati a tecnici e amministrazioni.

6.1 Sintesi dei risultati principali

Il lavoro svolto ha mostrato che modelli di regressione basati su indici satellitari sono in grado di ricostruire con elevata accuratezza la temperatura superficiale urbana normalizzata (`z_score`) sul territorio del Comune di Bologna, utilizzando i dati forniti dal progetto TALEA.

Dal confronto tra i tre algoritmi considerati (Regressione Lineare, Random Forest Regressor, Gradient Boosting Regressor) emerge in modo netto il ruolo centrale della Random Forest con feature estese. La configurazione che utilizza come input `ndvi_mean`, `albedo_mean`, `heat_veg_index` e `heat_retention_index` risulta essere il modello più accurato e robusto, con

valori di R^2 prossimi a 1, errori (RMSE, MAE) di ordine molto ridotto e prestazioni confermate anche in validazione incrociata 10-fold.

I risultati confermano in modo quantitativo la forte relazione fisica tra vegetazione, riflettanza e temperatura superficiale urbana. NDVI e albedo spiegano da soli la maggior parte della variabilità termica intraurbana: nei modelli base, la Random Forest che utilizza unicamente `ndvi_mean` e `albedo_mean` raggiunge già prestazioni quasi perfette, con importanze delle due feature sostanzialmente bilanciate. Questo indica che la combinazione di un indice biotico (presenza di vegetazione) e di un indice radiativo (capacità di riflettere la radiazione solare) è sufficiente a descrivere la struttura principale del campo termico urbano nel caso di Bologna.

L'introduzione degli indici compositi `heat_veg_index` e `heat_retention_index` fornisce un affinamento ulteriore. Nel modello esteso, tali indici assumono importanza non trascurabile e permettono una riduzione aggiuntiva degli errori rispetto al modello base, pur mantenendo NDVI e albedo come variabili dominanti. In pratica, gli indici compositi non sostituiscono le feature primarie, ma le integrano migliorando la rappresentazione delle condizioni termiche in contesti locali più complessi.

Al contrario, le feature derivate dall'NDVI di vicinato (medie entro 100, 200 e 500 m) non portano benefici significativi nel caso studiato. Le metriche del modello Random Forest che include `ndvi_mean_100m`, `ndvi_mean_200m` e `ndvi_mean_500m` risultano quasi identiche a quelle del modello con sole feature base e le importanze di queste variabili sono praticamente nulle. Ciò suggerisce che, per la risoluzione e la configurazione del dataset TALEA, l'NDVI locale della cella cattura già l'informazione rilevante sulla presenza di verde alla scala spaziale che maggiormente influenza la LST.

Infine, l'insieme dei risultati evidenzia anche la buona coerenza interna dei dati satellitari TALEA: il fatto che un modello relativamente standard come la Random Forest, alimentato da un numero limitato di indici derivati da immagini Landsat, sia in grado di ricostruire lo `z_score` con errori così contenuti indica che le relazioni tra vegetazione, riflettanza e temperatura sono rappresentate in modo stabile e consistente nel dataset. Questa coerenza contribuisce alle prestazioni elevate osservate e costituisce un presupposto importante per eventuali applicazioni operative e sviluppi futuri.

6.2 Implicazioni operative

I risultati ottenuti suggeriscono che un modello come la Random Forest con feature estese, addestrato su indici satellitari derivati (NDVI, albedo e indici compositi), può essere utilizza-

to come strumento operativo semplice e relativamente leggero per analizzare la temperatura superficiale urbana a scala di città.

Una prima implicazione riguarda l'analisi della variabilità termica intraurbana. A partire dai layer TALEA e dal modello addestrato, è possibile stimare lo `z_score` della LST per l'intero territorio comunale, ottenendo mappe ad alta risoluzione che evidenziano le aree relativamente più calde o più fresche. Questo tipo di output è utile per identificare in modo rapido i "punti caldi" (hotspot) e le zone con maggiore capacità di mitigazione legata alla presenza di vegetazione o a materiali ad elevata riflettanza.

In secondo luogo, il modello può essere impiegato come supporto alla progettazione di interventi di mitigazione. Poiché le feature principali sono direttamente interpretabili (NDVI e albedo), è possibile collegare le variazioni di output a cambiamenti realistici del tessuto urbano: incremento di copertura vegetale in specifiche aree, introduzione di materiali ad alta albedo su coperture o pavimentazioni, riqualificazione di spazi aperti. Pur non essendo un modello di simulazione fisica completa, la relazione appresa fornisce indicazioni quantitative sulla direzione e sull'ordine di grandezza degli effetti attesi sul campo termico.

Infine, il modello si presta a una valutazione esplorativa di scenari di modifica del tessuto urbano. Aggiornando le feature di input (ad esempio modificando NDVI e albedo in corrispondenza di un intervento ipotizzato) e riutilizzando lo stesso modello addestrato, è possibile confrontare rapidamente mappe "prima" e "dopo" a livello di `z_score` della LST. Questo approccio non sostituisce analisi più dettagliate basate su modelli fisici o microclimatici, ma può rappresentare uno strumento di screening iniziale, facile da aggiornare in presenza di nuovi dati satellitari e potenzialmente integrabile in notebook condivisibili o interfacce dedicate per tecnici e amministrazioni.

6.3 Sviluppi futuri

I risultati ottenuti mostrano che un modello relativamente semplice, basato su pochi indici satellitari, è in grado di descrivere in modo accurato la variabilità termica intraurbana nel caso di Bologna. Allo stesso tempo, l'analisi dei residui e i limiti discussi nel Capitolo 5 suggeriscono alcune direzioni naturali di sviluppo, utili sia per migliorare l'interpretabilità dei risultati sia per testare la robustezza del modello in contesti diversi.

Una prima linea di lavoro riguarda l'integrazione di feature urbanistiche esplicite. Attualmente il modello utilizza solo indici derivati da dati satellitari (NDVI, albedo e indici compositi), mentre la struttura urbana è rappresentata solo in modo indiretto. L'inclusione di variabili co-

me la densità degli edifici, l'altezza media del costruito, la distanza da aree verdi di diversa scala, la tipologia d'uso del suolo o indicatori di impermeabilizzazione permetterebbe di verificare se e in che misura tali fattori spiegano la parte residua della variabilità della LST che non viene catturata dagli indici satellitari. Dal punto di vista operativo, questo richiederebbe l'integrazione del dataset TALEA con informazioni provenienti da database urbanistici (GIS comunali, OpenStreetMap, catasti edilizi) e la definizione di feature derivate coerenti con la risoluzione spaziale delle mappe di temperatura superficiale.

Una seconda direzione importante è la generalizzazione temporale del modello. Tutta l'analisi svolta in questa tesi è riferita all'estate 2024 e a una specifica configurazione del clima urbano di Bologna in quel periodo. Per valutare la robustezza temporale delle relazioni apprese sarebbe utile testare lo stesso modello (o la stessa architettura di modello) su dati relativi ad altre stagioni o ad anni diversi, mantenendo un set di feature analogo. Questo permetterebbe di capire se i legami tra NDVI, albedo, indici compositi e `z_score` della LST rimangono stabili nel tempo o se emergono differenze legate a condizioni meteorologiche diverse, a cambiamenti nel tessuto urbano o a variazioni nella disponibilità di vegetazione. In prospettiva, un'estensione di questo tipo potrebbe portare alla costruzione di modelli multi-temporali, capaci di descrivere non solo la distribuzione spaziale della temperatura superficiale, ma anche la sua evoluzione stagionale e interannuale.

Bibliografia

[1] J. A. Voogt, T. R. Oke. Thermal remote sensing of urban climates. *Remote Sensing of Environment*, 86(3), 370–384, 2003.

[2] J. W. Rouse Jr., R. H. Haas, J. A. Schell, D. W. Deering. Monitoring vegetation systems in the Great Plains with ERTS. In *Third Earth Resources Technology Satellite-1 Symposium*, NASA SP-351, 1974.

[3] USGS. Landsat Missions. https://landsat.gsfc.nasa.gov/. Ultimo accesso: 28 novembre 2025.

[4] L. Breiman. Random Forests. *Machine Learning*, 45(1), 5–32, 2001.

[5] J. H. Friedman. Greedy function approximation: A gradient boosting machine. *Annals of Statistics*, 29(5), 1189–1232, 2001.

[6] T. Hastie, R. Tibshirani, J. Friedman. *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. 2nd ed., Springer, 2009.

[7] TALEA Platform. SUHI: Surface Urban Heat Island indicators for Bologna. Repository GitHub: https://github.com/TALEA-platform/suhi. Ultimo accesso: 28 novembre 2025.

[8] Python Software Foundation. Python Language Reference, version 3.x. https://www.python.org/. Ultimo accesso: 28 novembre 2025.

[9] F. Pedregosa et al. Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830, 2011. Documentazione: https://scikit-learn.org/stable/. Ultimo accesso: 28 novembre 2025.

[10] J. McKinney. Data Structures for Statistical Computing in Python. In *Proceedings of the 9th Python in Science Conference (SciPy 2010)*, pp. 51–56. Documentazione `pandas`: https://pandas.pydata.org/. Ultimo accesso: 28 novembre 2025.

[11] GeoPandas Developers. GeoPandas: Python tools for geographic data. https://geopandas.org/. Ultimo accesso: 28 novembre 2025.

[12] F. Malagutti. Codice e dati a supporto della tesi “Machine Learning per la stima della temperatura superficiale urbana da indici satellitari: applicazione a Bologna”. Repository GitHub: https://github.com/fabiomalagutti27-droid/tesi-machinelearning.

Ringraziamenti

Ringrazio tutta la mia famiglia per avermi sostenuto e accompagnato lungo questo percorso.

Ringrazio, per questo traguardo, tutte le persone che mi hanno aiutato durante questi anni e in quelli precedenti. In particolare ringrazio i miei genitori per avermi sostenuto e per avermi dato la possibilità e la libertà di autoaffermarmi.

Ringrazio mia mamma per essere stata sempre al mio fianco, per essersi sacrificata per me e per avermi dato la forza di continuare anche quando tutto sembrava impossibile.

Ringrazio mio padre per avermi aiutato a credere in me stesso e nelle mie capacità.

Ringrazio mia nonna per avermi trasmesso il senso del valore e per avermi insegnato a seguire sempre la mia strada.

Ringrazio Anna Paola e Giulia per aver condiviso con me la loro leggerezza nei momenti difficili.

Ringrazio Naty e Francesco per esserci sempre stati e per avermi accolto in una seconda casa.

Ringrazio Paty, Valerio, Sebastian e Jacopo per avermi fatto sentire sempre parte della loro famiglia.

Ringrazio tutti i miei amici per avermi aiutato durante il periodo di studio e per aver condiviso con me i momenti vissuti in questi anni.

Ringrazio Carolina per il suo sostegno instancabile, per avermi dato la forza di studiare quando ero esausto, per essere stata con me tra successi e fallimenti e per avermi aiutato a guardare al futuro senza dimenticare me stesso.